TP 1 - Filtrage Bayésien

Filtre de Kalman et filtre de Kalman étendu

Colin Gibet & Tom Cuel

September 29, 2026

Contents

Démarche **2**

1 Partie 0 – Classes Kalman et Kalman étendu **2**
1.1 Question a – Filtre de Kalman . . . 2
1.2 Question b – Filtre de Kalman étendu . . . 3
1.3 Conclusion . . . 3

2 Partie 1 – Localisation GNSS (Kalman 6D) **4**
2.1 Question a – Réglage nominal . . . 4
2.2 Question b – Trou de mesure ($10 < k < 20$) . . . 4
2.3 Questions c et d – Variation de Q et de R du filtre (et de $Q - R$ ensemble) . . . 5

3 Partie 2 – Localisation d'un robot par EKF **8**
3.1 Question 1 – Jacobiennes . . . 8
3.2 Question 2 – Panne capteur . . . 8
3.3 Question 3 – Erreurs de modèle . . . 10
3.4 Question 4 – Observabilité partielle . . . 12

4 Conclusion **14**

Démarche

Chaque partie est un script (`tp1_part0a.py`, `tp1_part0b.py`, `tp1_part1.py`, `tp1_part2_EKFLocalization.py`). Quand on compare plusieurs réglages, la graine aléatoire est fixée : **la vérité et les mesures simulées sont identiques**, seules les hypothèses du filtre changent. On distingue toujours deux choses :

- **la précision** : l'écart entre l'estimé et la vérité
- **la consistance** : l'erreur réelle reste-t-elle dans l'incertitude $\pm 3\sigma$ que le filtre annonce ? Un filtre peut être précis et se tromper sur sa propre incertitude

1 Partie 0 – Classes Kalman et Kalman étendu

1.1 Question a – Filtre de Kalman

La classe `KalmanFilter` implémente les deux étapes du cours :

$$\text{prédiction :}\quad \hat{x}_{k|k-1} = F\hat{x}_{k-1}, \quad P_{k|k-1} = FP_{k-1}F^T + Q$$

$$\text{correction :}\quad K_k = P_{k|k-1}H^T S_k^{-1}, \quad \hat{x}_k = \hat{x}_{k|k-1} + K_k(y_k - H\hat{x}_{k|k-1}), \quad P_k = (I - K_k H)P_{k|k-1}$$

Les modèles d'évolution et d'observation sont linéaires (F et H sont des matrices constantes) et les bruits gaussiens : le filtre de Kalman est alors exact, et P_k comme K_k ne dépendent pas des mesures.

Vérification sur l'exemple de la slide 6

Avec $y_1 = 29.91$, le code retrouve exactement les valeurs du cours :

$$\hat{x}_{1|0} = \begin{bmatrix}10\\10\end{bmatrix}, \quad P_{1|0} = \begin{bmatrix}102 & 1\\1 & 1.001\end{bmatrix}, \quad S_1 = 103, \quad \boxed{K_1 = \frac{1}{103}\begin{bmatrix}102\\1\end{bmatrix} = \begin{bmatrix}0.990\\0.010\end{bmatrix}}, \quad \hat{x}_1 = \begin{bmatrix}29.72\\10.19\end{bmatrix}, \quad P_1 = \begin{bmatrix}0.990 & 0.010\\0.010 & 0.991\end{bmatrix}$$

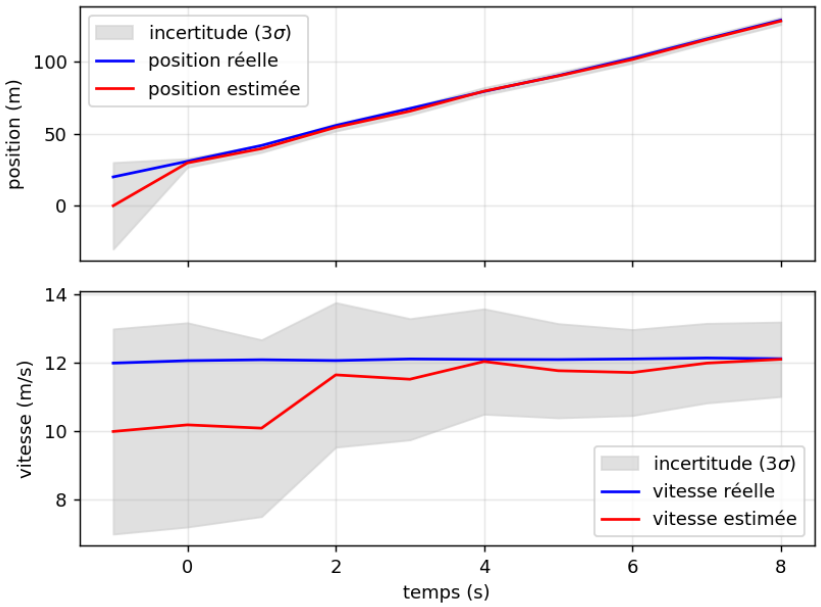


Figure 1: Filtre de Kalman : position (mesurée) et vitesse (non mesurée)

k	1	2	3	4	5	6	7	8	9
gain position K_k^p	0.99	0.75	0.75	0.73	0.71	0.70	0.68	0.67	0.67
gain vitesse K_k^v	0.01	0.25	0.25	0.20	0.16	0.13	0.11	0.09	0.08

Table 1: Évolution du gain de Kalman

Interprétation

- **Premier pas** : l'a priori est très incertain devant la mesure ($P_{1|0} = 102 \gg R = 1$). Le gain en position vaut presque 1 : le filtre fait entièrement confiance à la mesure et la position « saute » sur elle
- **Pas suivants** : la position est désormais connue à environ 1 m près, comparable à la précision de la mesure. Le gain chute à 0.75 : le filtre fait maintenant une moyenne pondérée entre sa prédiction et la mesure, et ajuste l'estimé progressivement

- **Vitesse** : elle n'est jamais mesurée, et au premier pas son gain est presque nul (une seule position ne dit rien sur la vitesse). Dès le deuxième pas, l'écart entre la position prédite et la position mesurée renseigne sur l'erreur de vitesse : le gain en vitesse monte à 0.25, puis décroît à mesure que la vitesse est mieux connue. Cette correction passe par la covariance croisée position/vitesse que crée la prédiction
- **Incertitude** : elle décroît puis se stabilise quand l'information apportée par chaque mesure compense le bruit de dynamique, justifiant le bon fonctionnement du filtre

1.2 Question b – Filtre de Kalman étendu

La classe `ExtendedKalmanFilter` propage l'estimé par les fonctions non linéaires et la covariance par leurs jacobiennes. Ici la dynamique est linéaire et seule la mesure (angle vu depuis le capteur en $(0, -20)$) ne l'est pas :

$$h(x) = \text{atan2}(20, s) \qquad \Rightarrow \qquad \boxed{H = \begin{bmatrix} \frac{-20}{s^2 + 400} & 0 \end{bmatrix}}$$

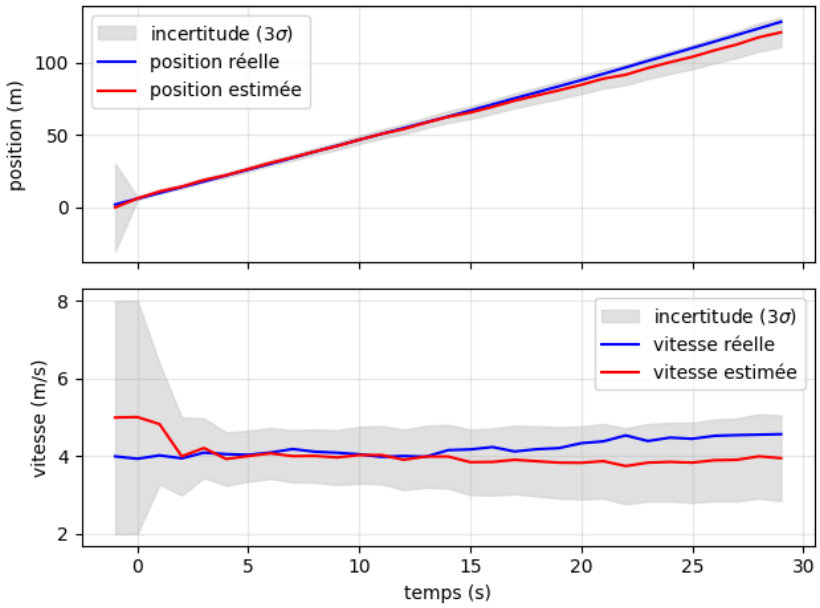


Figure 2: EKF avec une mesure d'angle seule

Qu'observe-t-on ?

Contrairement au cas précédent, l'incertitude en position n'est pas décroissante : elle chute brutalement à la première mesure, puis **augmente régulièrement** alors qu'une mesure arrive à chaque pas. L'incertitude en vitesse diminue puis remonte lentement. En fin de simulation l'estimé s'écarte un peu de la vérité, en restant dans l'enveloppe.

Pourquoi ?

C'est un effet de **géométrie**, visible dans H : la sensibilité de l'angle à la position décroît en $1/s^2$.

- Au départ la cible est proche du capteur : un degré d'erreur angulaire correspond à quelques dizaines de centimètres, une seule mesure localise très bien la cible
- La cible s'éloigne : le même degré correspond à plusieurs mètres. Chaque mesure apporte de moins en moins d'information et ne compense plus le bruit de dynamique, donc l'incertitude remonte
- Le filtre reste bien meilleur qu'une mesure isolée, car la dynamique accumule l'information passée via la vitesse

1.3 Conclusion

Dans le cas linéaire, F et H sont constantes : P_k et K_k ne dépendent pas des mesures et sont connus à l'avance. Pour l'EKF, H est évaluée en $\hat{x}_{k|k-1}$: P_k dépend de l'estimé et reflète l'information réellement disponible, d'où une incertitude qui peut remonter. Si l'estimé était très éloigné de la vérité, H serait calculée au mauvais endroit et le filtre pourrait diverger.

2 Partie 1 – Localisation GNSS (Kalman 6D)

État $X_k = (\mathrm{Pos}_k, \mathrm{Vel}_k) \in \mathbb{R}^6$, modèle à vitesse constante, mesure de la position seule. Les trois axes sont indépendants : on commente l'axe x, les autres se comportent de la même façon (on les montre quand même).

$$\text{prédiction :} \quad X_k = \begin{bmatrix} I_3 & \Delta t I_3 \\ 0 & I_3 \end{bmatrix} X_{k-1} + \nu_k$$
$$\text{observation :} \quad Y_k = \begin{bmatrix} I_3 & 0_3 \end{bmatrix} X_k + v_k$$

2.1 Question a – Réglage nominal

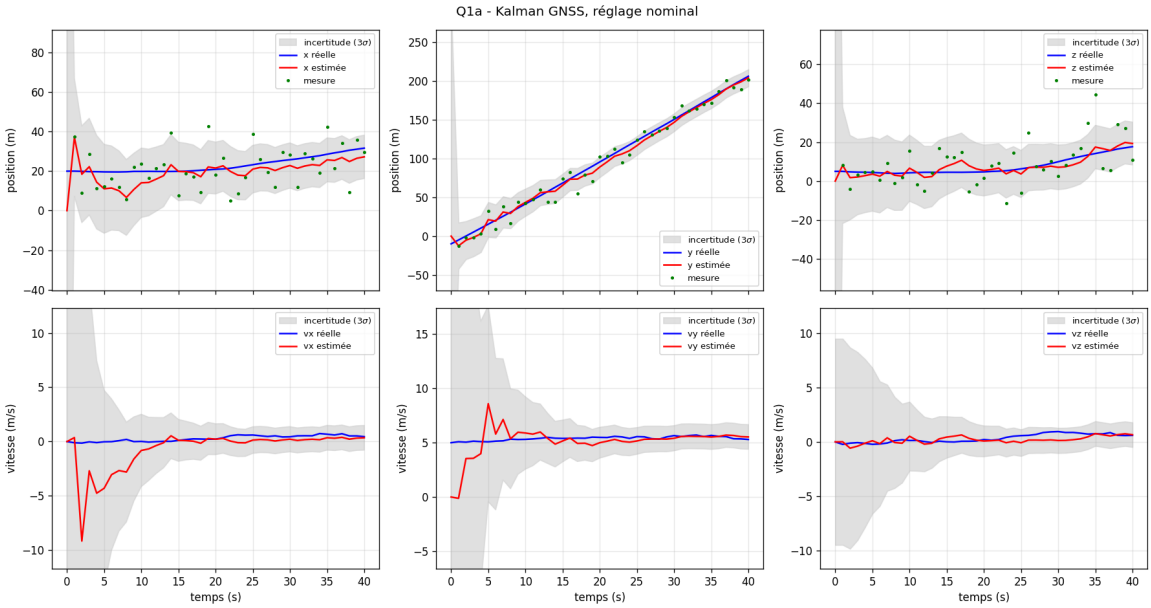


Figure 3: Kalman 6D : vérité, estimation, bande $\pm 3\sigma$ et mesures

Comme prévu dans la partie précédente, on obtient une convergence des résultats jusqu'à une erreur stagnante qui correspond à la compensation du bruit par l'observation. Bien que la vitesse ne soit jamais mesurée, elle est estimée de mieux en mieux grâce à la corrélation avec la position. Son incertitude décroit régulièrement.

2.2 Question b – Trou de mesure ($10 < k < 20$)

Pour simuler une absence de mesure pour $k \in]10, 20[$, on va propager $\hat{x}_{k-1}$ vers $\hat{x}_k$ sans terme de correction, donc on aura une relation linéaire sur ces segments. En effet, la seule étape sera l'ajout du terme constant selon : $\hat{x}_{k+1} = F\hat{x}_k$.

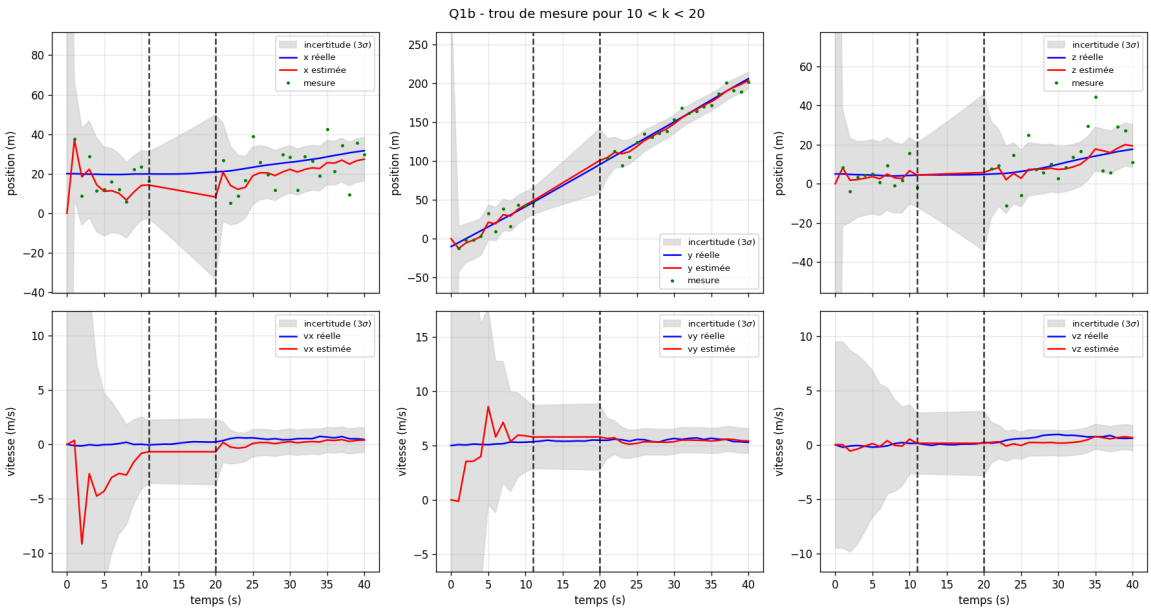


Figure 4: Pas de mesure entre les deux traits pointillés : prédiction seule

Qu'observe-t-on ?
Sans mesure, seule la prédiction est appliquée : l'estimé est **extrapolé en ligne droite** avec la dernière vitesse estimée. L'incertitude sur la position **croît linéairement**, alors que celle sur la vitesse reste presque constante. Dès le retour des mesures, l'estimé est ramené vers elles et l'incertitude redescend.

Pourquoi ?
Pendant le trou, seule $P_{k+1|k} = FP_{k|k-1}F^T + Q$ est appliquée. Sur un axe, avec $F = \begin{bmatrix} 1 & \Delta t \\ 0 & 1 \end{bmatrix}$:

$$\boxed{P'_{vv} = P_{vv} + q_v, \qquad P'_{pv} = P_{pv} + \Delta t\, P_{vv}, \qquad P'_{pp} = P_{pp} + 2\Delta t\, P_{pv} + \Delta t^2 P_{vv} + q_p}$$

- **Vitesse** : elle ne dépend pas de la position (ligne [0 1] de F) : sa variance ne gagne que le petit bruit de processus q_v à chaque pas, d'où une bande quasi plate
- **Position** : elle intègre l'incertitude de vitesse : après j pas, $P_{pp} \approx P_{pp} + j^2 P_{vv}$, donc $\sigma_x \approx j\,\sigma_v$ croît linéairement. L'erreur réelle suit le même mécanisme : l'erreur de vitesse, figée, s'accumule en erreur de position
- **Retour des mesures** : pendant le trou, position et vitesse deviennent très corrélées. La première mesure a donc un gain fort sur la position, et corrige aussi la vitesse à travers cette corrélation

Le point important est que l'erreur reste dans la bande pendant tout le trou : **le filtre sait qu'il perd en précision**.

2.3 Questions c et d – Variation de Q et de R du filtre (et de $Q - R$ ensemble)

Le système simulé ne change pas, on multiplie le Q (resp. le R) **utilisé par le filtre** par 0.01, 0.1, 1, 10 et 100.

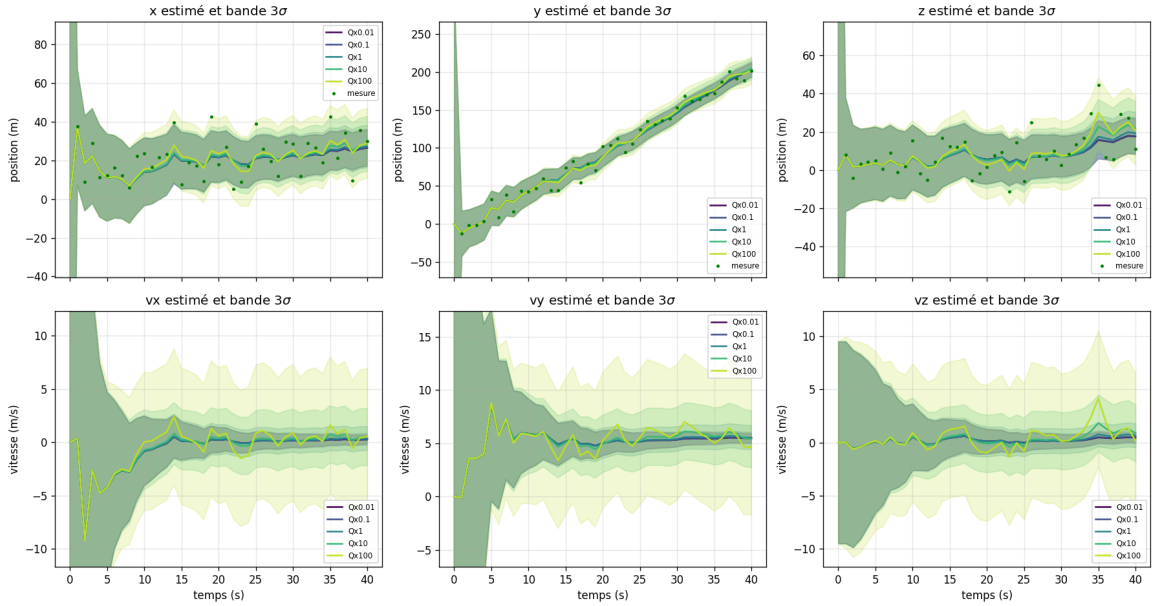


Figure 5: Variation de Q : estimations et bandes $\pm 3\sigma$, une couleur par facteur

Table 2: Variation de Q

Facteur	RMSE pos. $k \geq 25$	RMSE vit. $k \geq 25$	K_{xx} final
0.01	3.45	0.401	0.097
0.1	3.41	0.396	0.101
1	3.22	0.370	0.134
10	3.32	0.423	0.223
100	4.23	0.832	0.362

Quand Q augmente, la bande s'élargit un peu sur la position mais beaucoup sur la vitesse. La position est mesurée à chaque pas, son incertitude reste donc limitée par l'erreur d'observation. La vitesse n'est corrigée qu'indirectement, et son incertitude suit directement le bruit de dynamique supposé, elle augmente donc proportionnellement à Q.

- Q **grand** : le filtre doute de son modèle, le gain est grand et l'estimé suit les mesures. Il est plus bruité, surtout en vitesse, mais réagirait plus vite à une manœuvre
- Q **petit** : le filtre se fie à son modèle, l'estimé est très lisse mais la bande est trop étroite : le filtre est **trop confiant**. Sur un horizon long, un filtre qui ignore les mesures finit par décrocher de la vraie trajectoire

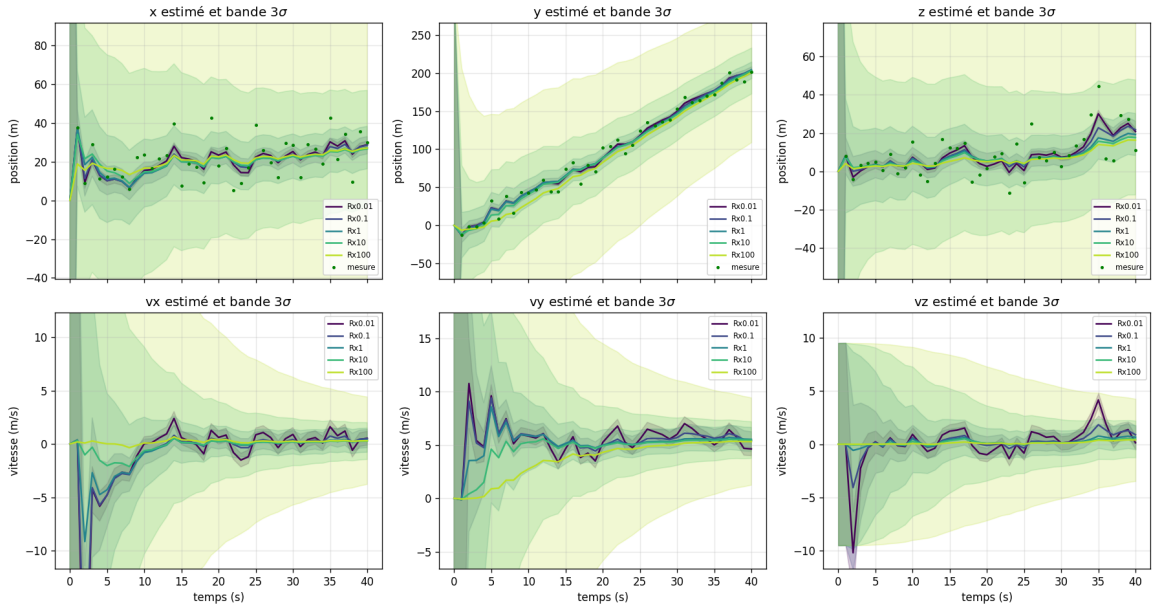


Figure 6: Variation de R

Table 3: Variation de R

Facteur	RMSE pos. $k \geq 25$	RMSE vit. $k \geq 25$	K_{xx} final
0.01	4.23	0.832	0.362
0.1	3.32	0.423	0.223
1	3.22	0.370	0.134
10	3.51	0.399	0.101
100	4.85	0.454	0.093

Effet symétrique : quand R augmente, la bande de position s'élargit fortement, car le filtre fait moins confiance aux mesures, seule source d'information sur la position. La vitesse, pilotée surtout par le modèle, reste bien estimée.

- R **petit** : le filtre croit ses mesures exactes, l'estimé colle aux mesures bruitées et la bande est bien trop étroite
- R **grand** : les mesures sont presque ignorées, la convergence est lente (visible sur la vitesse au début) et la bande devient très large

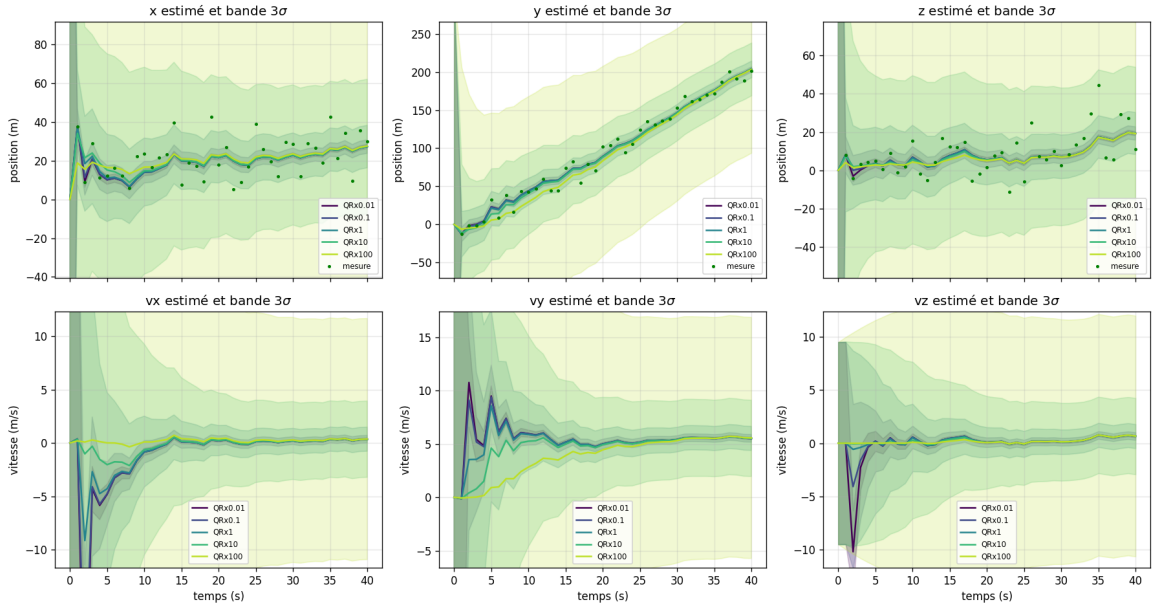


Figure 7: Variation de QR : estimations et bandes $\pm 3\sigma$, une couleur par facteur

Table 4: Variation de QR

Facteur	RMSE pos. $k \geq 25$	RMSE vit. $k \geq 25$	K_{xx} final
0.01	3.21	0.370	0.134
0.1	3.21	0.370	0.134
1	3.22	0.370	0.134
10	3.27	0.370	0.134
100	3.88	0.371	0.133

Multiplier Q et R par le même facteur ne change pas le gain, donc l'estimé reste le même. Seule la largeur de la bande change : elle est trop étroite pour les petits facteurs et trop large pour les grands.

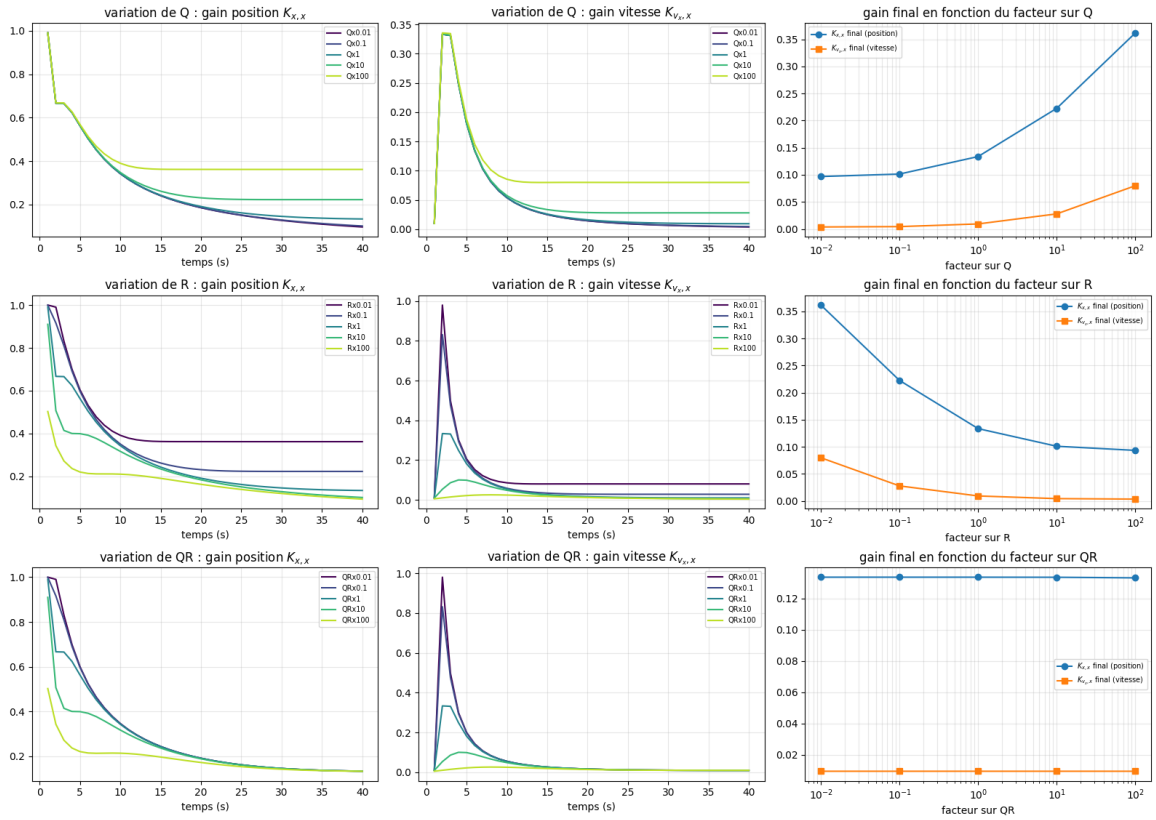


Figure 8: Gains de Kalman en position et en vitesse (axe x) au cours du temps, et gain final selon le facteur. Lignes : Q multiplié, R multiplié, Q et R multipliés ensemble

Clé de lecture : le gain

Q représente la confiance dans le modèle de dynamique, R la confiance dans les mesures. Le gain K arbitre entre les deux (figure 8) : il augmente avec Q et diminue avec R., sans être modifié si les deux sont multipliés par le même facteur (QR).

	facteur sur Q		**facteur sur R**	
facteur	RMSE pos (m)	K_{xx} final	RMSE pos (m)	K_{xx} final
0.01	3.45	0.10	4.23	0.36
1	**3.22**	0.13	**3.22**	0.13
100	4.23	0.36	4.85	0.09

Table 5: Erreur de position en régime établi et gain final

3 Partie 2 – Localisation d'un robot par EKF

Le robot connaît son déplacement par odométrie (précise en translation, bruitée en cap) et observe à chaque pas la distance et la direction d'un amer connu. Son état est représenté par X_t, son mouvement entre t et $t+1$ par U_t, et sa mesure par Y_t :

$$X_t = \begin{bmatrix} x_t \\ y_t \\ \theta_t \end{bmatrix}, \quad U_t = \begin{bmatrix} x_u \\ y_u \\ \theta_u \end{bmatrix}, \quad Y_t = \begin{bmatrix} r_t^k \\ \phi_t^k \end{bmatrix}^T$$

$$X_{t+1} = f(X_t, u_t) = \begin{bmatrix} x_t + x_u \cos\theta_t - y_u \sin\theta_t \\ y_t + x_u \sin\theta_t + y_u \cos\theta_t \\ \theta_t + \theta_u \end{bmatrix}$$

$$Y_t = h^k(X_t^*) = \begin{bmatrix} \sqrt{(x_k - x_t)^2 + (y_k - y_t)^2} \\ \text{atan2}(y_k - y_t, x_k - x_t) - \theta_t \end{bmatrix}$$

3.1 Question 1 – Jacobiennes

$$A = \begin{bmatrix} 1 & 0 & -x_u \sin\theta - y_u \cos\theta \\ 0 & 1 & x_u \cos\theta - y_u \sin\theta \\ 0 & 0 & 1 \end{bmatrix}, \quad B = \begin{bmatrix} \cos\theta & -\sin\theta & 0 \\ \sin\theta & \cos\theta & 0 \\ 0 & 0 & 1 \end{bmatrix}, \quad H = \begin{bmatrix} -\frac{x_k - x_t}{r} & -\frac{y_k - y_t}{r} & 0 \\ \frac{y_k - y_t}{(x_k - x_t)^2 + (y_k - y_t)^2} & -\frac{x_k - x_t}{(x_k - x_t)^2 + (y_k - y_t)^2} & -1 \end{bmatrix}$$

Le bruit porte sur la commande, d'où la prédiction $P_{k+1|k} = AP_kA^T + BQ_{Est}B^T$. On note que la distance ne dépend pas du cap ($\partial r / \partial \theta = 0$) : ce point est central pour la question 4.

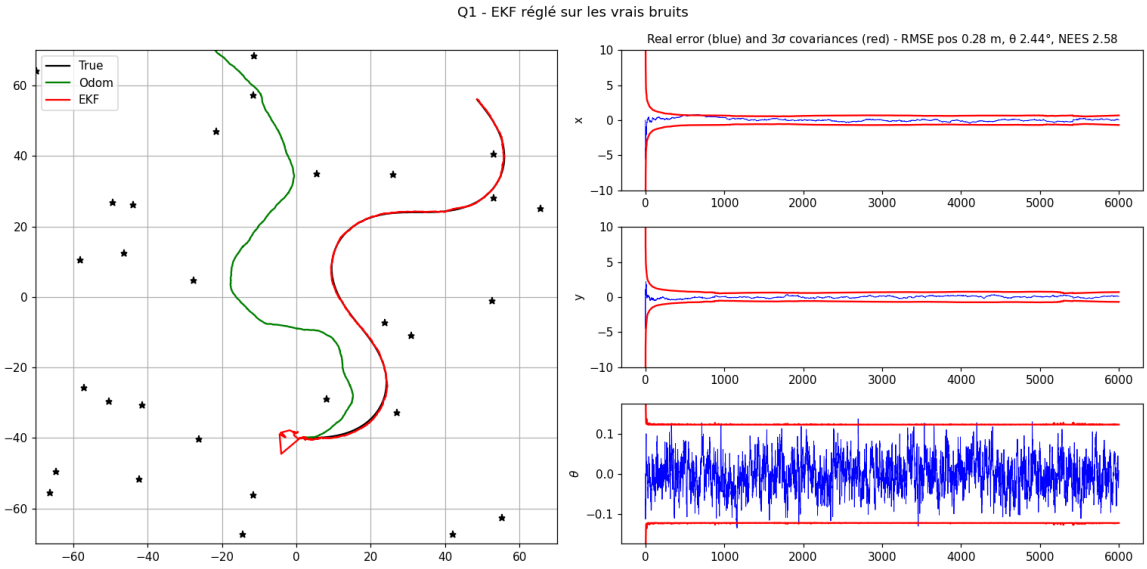


Figure 9: EKF avec le réglage fourni / Gauche : trajectoires / Droite : erreur réelle et bande $\pm 3\sigma$

Question	Scénario	RMSE pos.	RMSE θ	$\pm 3\sigma$	NEES (att. 3)
Q1	exact (1,1)	0.28 m	2.44°	97.6%	2.58

Que représentent les trois courbes de droite ?
Pour x, y et θ : en bleu **l'erreur réelle** $\hat{x}_k - x_k$ (connue seulement en simulation), en rouge l'enveloppe $\pm 3\sigma$ tirée de P_k, c'est-à-dire l'incertitude que le filtre **s'attribue**. Tant que la courbe bleue reste dans l'enveloppe, le filtre est cohérent.

Observations

- L'odométrie seule (vert) dérive de plusieurs dizaines de mètres, alors que l'EKF (rouge) reste "collé" à la vérité : l'erreur de position reste de l'ordre de quelques dizaines de centimètres
- L'erreur de cap est corrigée à chaque pas par la direction mesurée, d'où une erreur rapide mais bornée

3.2 Question 2 – Panne capteur

`get_observation` renvoie `None` pendant la panne : le filtre ne reçoit plus de mesure et ne fait que la prédiction, $\hat{x}_k = \hat{x}_{k|k-1}$ et $P_k = P_{k|k-1}$. On teste deux fenêtres, $2500 < k < 3500$ et $1000 < k < 2500$ (bruits du filtre exacts).

Pendant la panne
L'EKF devient une **navigation à l'estime** : il intègre l'odométrie à partir de sa dernière bonne estimation, et sa trajectoire (orange) dérive comme le ferait l'odométrie.

- **Cap** : le bruit de cap s'additionne à chaque pas (marche aléatoire), l'incertitude croît en $\sqrt{k}$
- **Position** : elle croît plus vite, car une erreur de cap se transforme en erreur de position à chaque déplacement (effet de bras de levier)
- **Consistance** : l'erreur réelle grandit mais reste dans l'enveloppe, qui s'ouvre plus vite qu'elle

Au retour des mesures

$P_{k|k-1}$ étant devenu très grand, le gain l'est aussi : l'estimé saute presque instantanément vers la vérité et l'enveloppe se referme en quelques pas. Ce recalage est possible parce que l'amer observé est **identifié sans ambiguïté** : distance et direction vers un point connu fixent directement la pose.

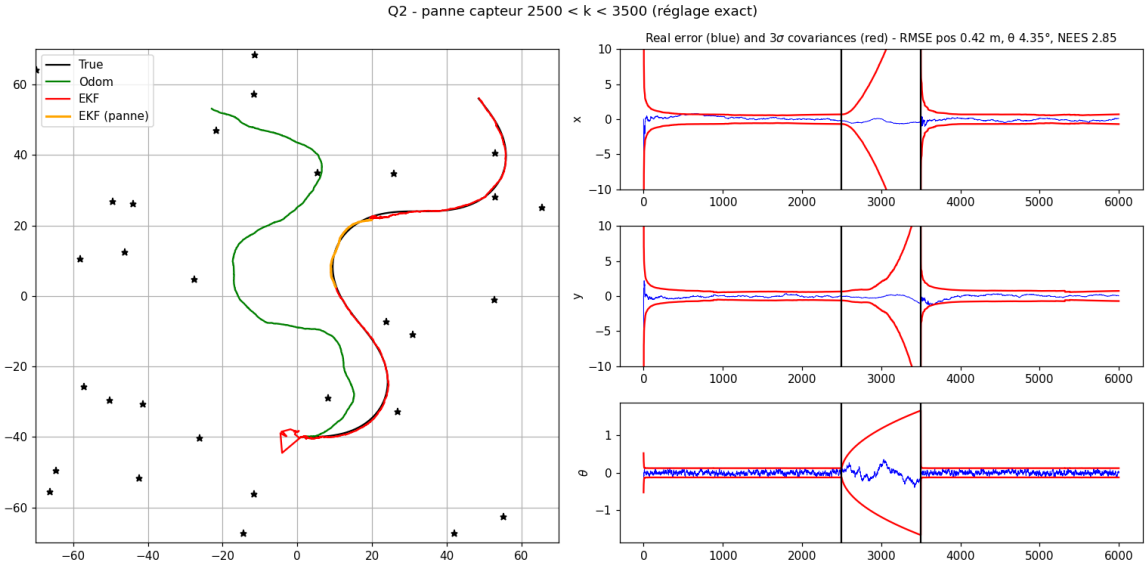


Figure 10: Panne capteur entre les deux traits noirs ($2500 < k < 3500$)

Observation du cas de l'énoncé du TP

Cependant, ici le suivi de la trajectoire durant la panne fait que l'erreur de cap n'est que peu visible sur la trajectoire, car il n'y a pas de virage durand la panne. Les descriptions précédentes restent valables pour l'analyse des erreurs.

Prenons maintenant un autre exemple, juste avant un changement de trajectoire:

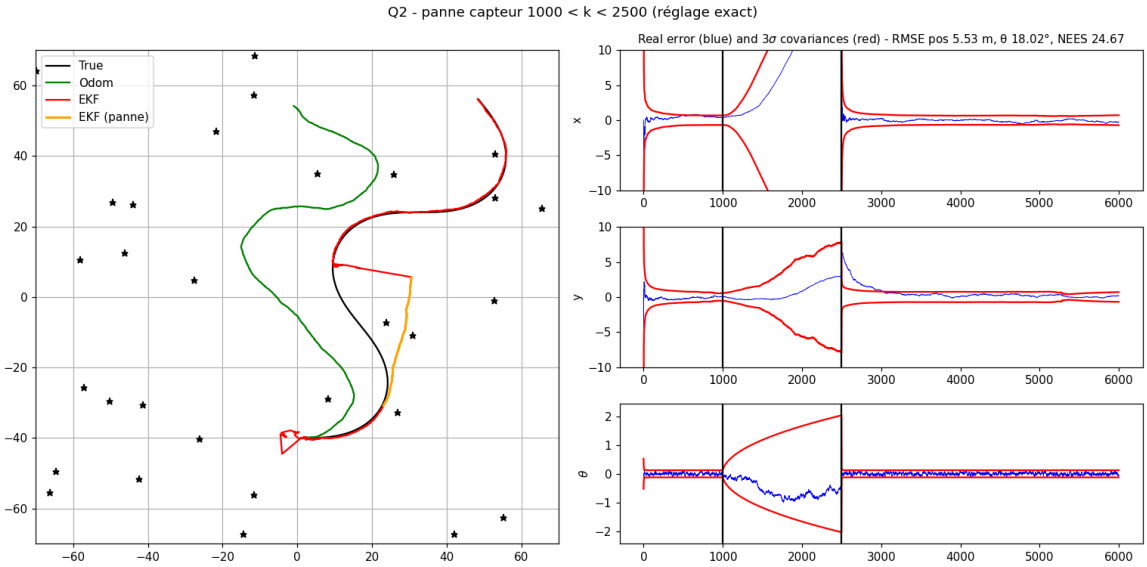


Figure 11: Panne capteur entre les deux traits noirs ($1000 < k < 2500$)

Observation de notre cas personnel

L'odométrie contient bien les virages, mais l'erreur de cap accumulée pendant la panne suffit ici à les compenser : l'estimé part tout droit (orange) pendant que la trajectoire tourne. La panne étant plus longue, l'erreur de cap atteint plusieurs dizaines de degrés. Les incertitudes s'ouvrent de la même manière que dans le cas précédent. À ce niveau, la

linéarisation n'est plus valable : au retour des mesures, l'erreur sort de l'enveloppe pendant quelques pas, avant que le filtre ne se recale, retrouvant la trajectoire correcte.

Fenêtre de panne	RMSE pos.	RMSE θ	temps dans $\pm 3\sigma$	NEES (att. 3)
$2500 < k < 3500$	0.42 m	4.4°	97.5 %	2.9
$1000 < k < 2500$	5.5 m	18°	88.7 %	24.7

Table 6: Une panne courte reste bien gérée, une panne longue dégrade la précision et surtout la consistance

3.3 Question 3 – Erreurs de modèle

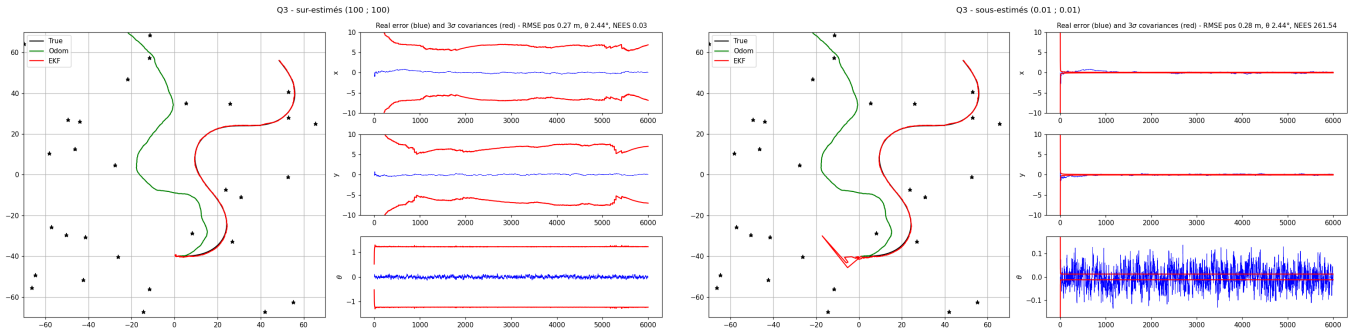
On multiplie les bruits **supposés par le filtre** (Q_{Est} et $P_{Y,Est}$) par rapport aux vrais bruits du simulateur, le monde simulé restant le même.

Table 7: Résultats de filtrage pour différents bruits supposés par le filtre

Question	Scénario	RMSE pos.	RMSE θ	$\pm 3\sigma$	NEES (att. 3)
Q3	exact (1,1)	0.28 m	2.44°	97.6%	2.58
Q3	draft (10,10)	0.27 m	2.44°	100.0%	0.26
Q3	sur-estimés (100,100)	0.27 m	2.44°	100.0%	0.03
Q3	sous-estimés (0.01,0.01)	0.28 m	2.44°	2.5%	261.54
Q3	odom bruitée, perception précise (100,0.01)	2.72 m	6.69°	3.1%	213.05
Q3	odom précise, perception bruitée (0.01,100)	1.96 m	18.69°	22.5%	74.64
Q3	distance x100, direction exacte	0.37 m	2.45°	99.3%	2.72
Q3	distance x1e4, direction exacte	0.37 m	2.45°	99.3%	2.73

Bruits grossièrement sur- ou sous-estimés (même facteur partout)

Comme en partie B, seul le rapport entre les bruits fixe le gain : **l'estimé est inchangé**, seule la covariance annoncée est fausse. Surestimés, l'enveloppe est énorme et le filtre inutilement pessimiste. Sous-estimés, l'enveloppe est très étroite et l'erreur en sort presque tout le temps : le filtre est **sûr de lui à tort**, ce qui est dangereux en pratique (rejet de mesures valides, décisions sur une précision imaginaire). De manière remarquable, l'EKF suit la vraie trajectoire correctement même quand il est sûr de lui à tort : la linéarisation reste valable et le filtre ne diverge pas.



(a) Bruits sur-estimés

(b) Bruits sous-estimés

Figure 12: Bruits supposés par le filtre : sur- ou sous-estimés par rapport à la réalité

Perception jugée très précise, odométrie jugée très bruitée

Le filtre fait une confiance aveugle à chaque mesure : l'estimé saute à chaque pas vers la pose compatible avec la dernière observation, et la trajectoire devient un **zigzag**. Or une seule mesure (2 composantes) ne contraint pas complètement la pose (3 composantes) et elle est en réalité bruitée : l'erreur est multipliée par dix. Le filtre se prive aussi de l'odométrie, pourtant très précise en translation. Son enveloppe, très étroite, ne contient presque jamais l'erreur.

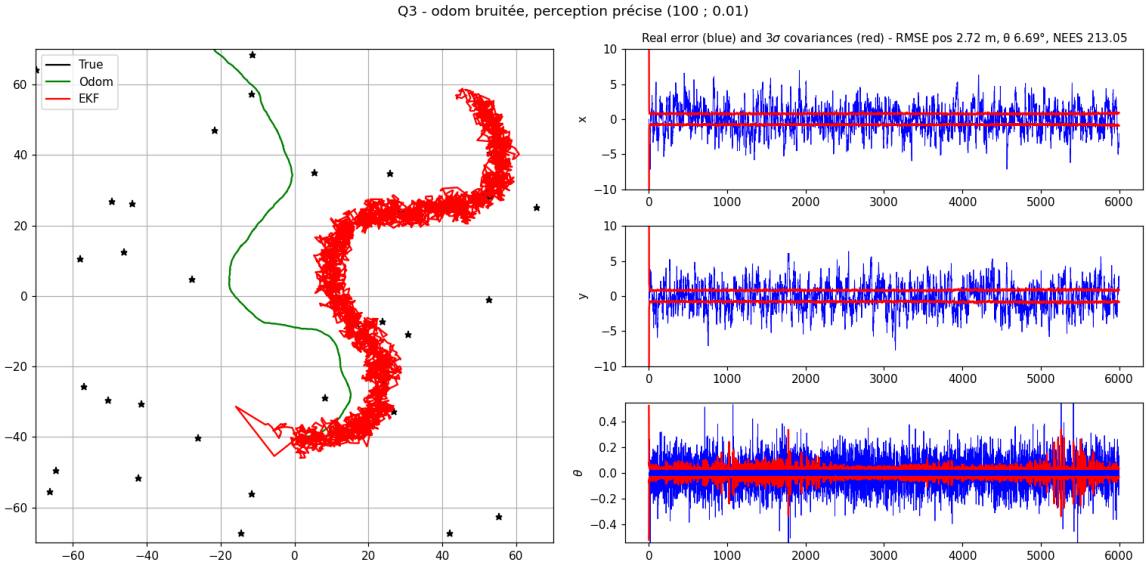


Figure 13: Perception jugée très précise, odométrie jugée très bruitée

Cas inverse : odométrie jugée très précise, perception très bruitée

Le filtre suit essentiellement l'odométrie : la trajectoire est **lisse mais en retard**. Le cap dérive lentement et les mesures ne le corrigent qu'avec beaucoup de retard, l'erreur de cap atteignant plusieurs dizaines de degrés par moments. L'enveloppe du cap est bien trop étroite.

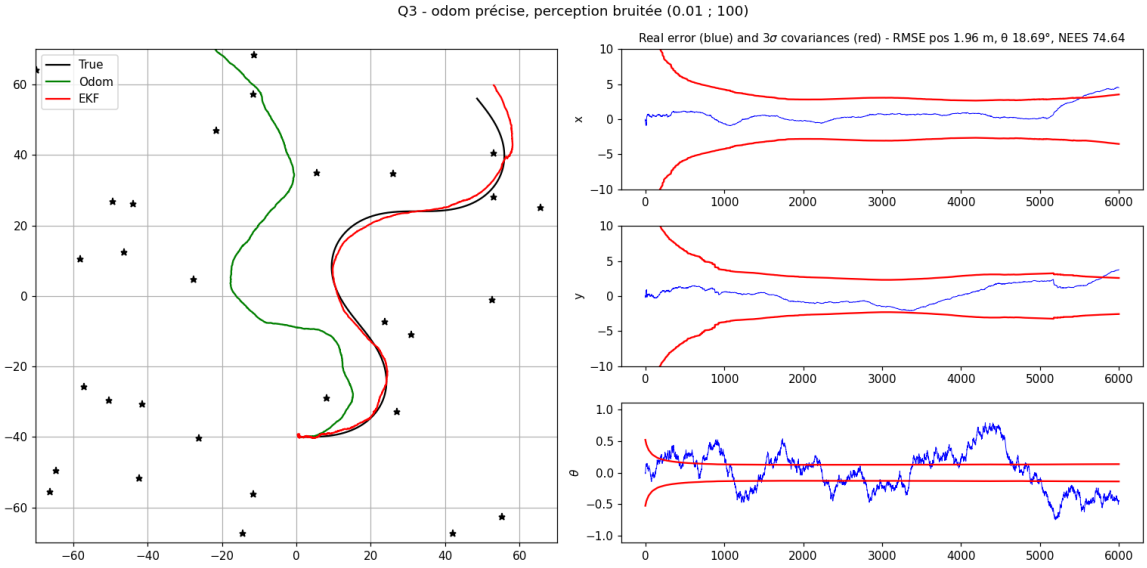


Figure 14: Perception jugée très bruitée, odométrie jugée très précise

Distance très bruitée, direction exacte

Presque aucun effet, même quand la distance est quasiment ignorée. La direction suffit : elle observe directement le cap et, sur des amers de directions différentes, la position par triangulation. La distance n'apporte qu'un complément.

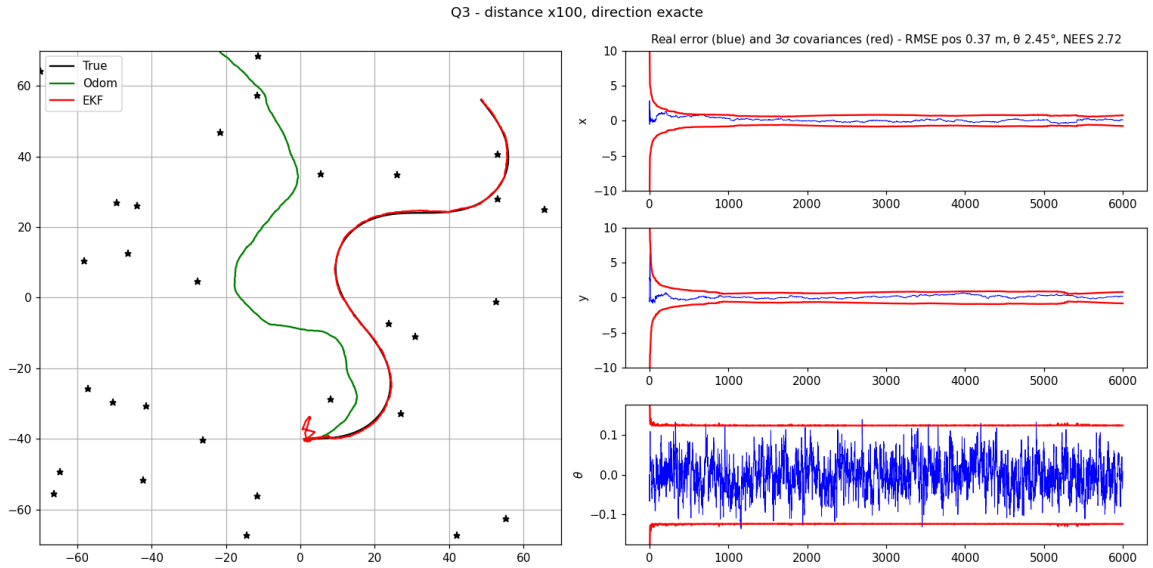


Figure 15: Distance très bruitée, direction exacte

Table 8: Résultats des différents scénarios de modification des bruits supposés par le filtre

Question	Scénario	RMSE pos.	RMSE θ	$\pm 3\sigma$	NEES (att. 3)
Q3	exact (1,1)	0.28 m	2.44°	97.6%	2.58
Q3	draft (10,10)	0.27 m	2.44°	100.0%	0.26
Q3	sur-estimés (100,100)	0.27 m	2.44°	100.0%	0.03
Q3	sous-estimés (0.01,0.01)	0.28 m	2.44°	2.5%	261.54
Q3	odom bruitée, perception précise (100,0.01)	2.72 m	6.69°	3.1%	213.05
Q3	odom précise, perception bruitée (0.01,100)	1.96 m	18.69°	22.5%	74.64
Q3	distance x100, direction exacte	0.37 m	2.45°	99.3%	2.72
Q3	distance x1e4, direction exacte	0.37 m	2.45°	99.3%	2.73

3.4 Question 4 – Observabilité partielle

Pour n'utiliser que la distance ou la direction, on réduit la mesure à une composante : H devient 1×3 (la ligne correspondante de la jacobienne), P_Y devient 1×1, l'innovation devient scalaire (ramenée dans $]-\pi, \pi]$ si c'est un angle), puis S, W et la mise à jour s'appliquent sans autre changement.

```
def get_obs_jac(xPred, iFeature, Map, partial_obs=None):
# fonction conservee avec tous les calculs coefs par coefs a la main : voici ici une version plus elegante
    dx = Map[0, iFeature] - xPred[0, 0]
    dy = Map[1, iFeature] - xPred[1, 0]
    q = dx**2 + dy**2
    r = sqrt(q)

    jac_distance = [-dx / r, -dy / r, 0]       # d r / d(x, y, theta)
    jac_direction = [dy / q, -dx / q, -1]      # d phi / d(x, y, theta)

    if partial_obs == "distance":
        jH = np.array([jac_distance])
    elif partial_obs == "direction":
        jH = np.array([jac_direction])
    else:
        jH = np.array([jac_distance, jac_direction])
    return jH
```

```
H = get_obs_jac(xPred, iFeature, Map, partial_obs)   # 1x3 si partial_obs = "distance" ou "direction"
Innov = z - zPred                                    # 1x1
S = H @ PPred @ H.T + PYEst                          # PYEst : 1x1
W = PPred @ H.T @ np.linalg.inv(S)                   # 3x1
xEst = xPred + W @ Innov
```

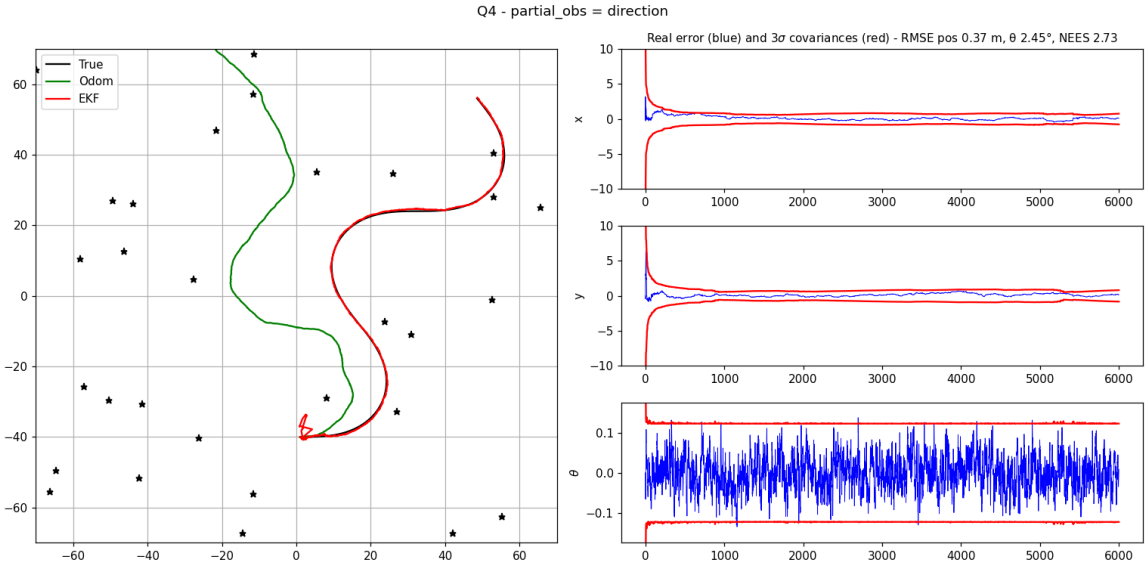


Figure 16: Direction seule

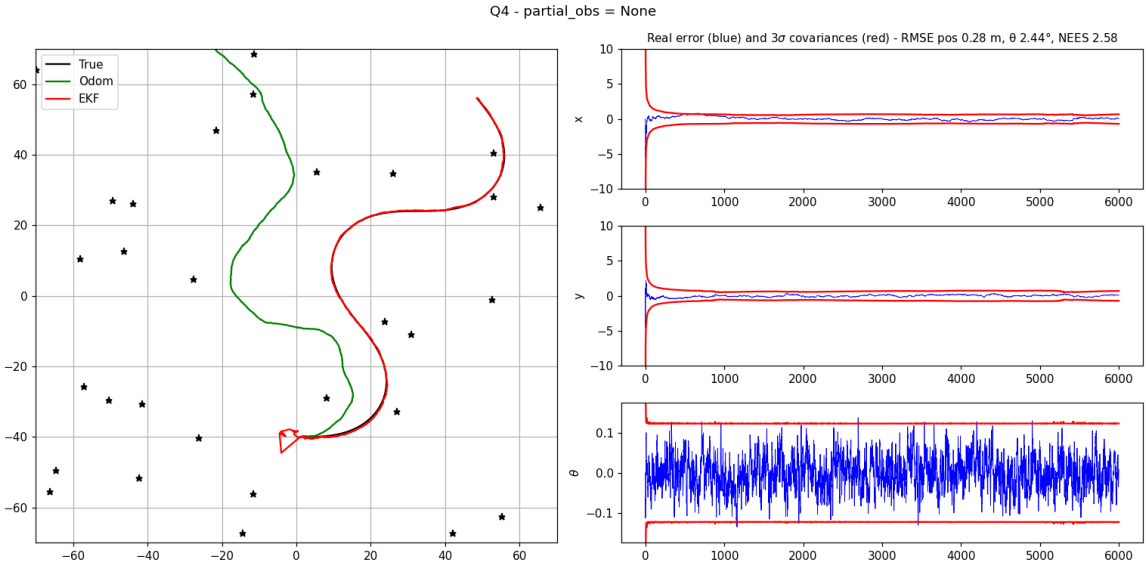


Figure 17: Direction et distance

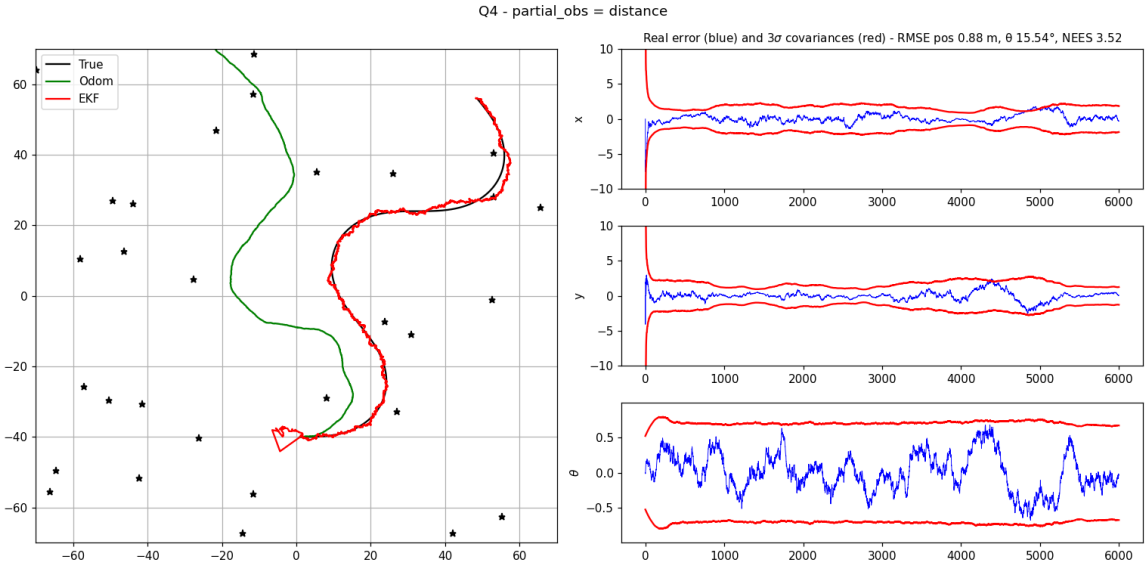


Figure 18: Distance seule

Table 9: Résultats comparatifs pour les trois scénarios de mesure

Question	Scénario	RMSE pos.	RMSE θ	$\pm 3\sigma$	NEES (att. 3)
Q4	partial_obs = direction	0.37 m	2.45°	99.3%	2.73
Q4	partial_obs = distance + direction	0.28 m	2.44°	97.6%	2.58
Q4	partial_obs = distance	0.88 m	15.54°	96.8%	3.52

Direction seule
Les performances sont **quasiment identiques au cas complet**. La direction dépend directement du cap, qu'elle corrige à chaque mesure, et plusieurs directions vers des amers différents suffisent à trianguler la position.

Distance seule
La position reste bien estimée, par trilatération sur des amers successifs, mais **le cap est nettement moins bien connu** (erreur de l'ordre de 15° contre 2°). La distance ne dépend pas du cap : il n'est observable qu'**indirectement, par le mouvement**, en comparant les positions successives du robot. Comme le robot avance lentement par rapport à son incertitude de position, cette information est faible. Le filtre reste cohérent : il annonce lui-même une grande incertitude sur le cap.

Conclusion
La direction est ici la mesure la plus utile, car l'erreur dominante du système est celle du cap de l'odométrie et c'est la seule mesure qui l'observe. Le filtre de Kalman gère naturellement ces observations partielles : une mesure scalaire met à jour les trois composantes à travers les corrélations de P, et l'état reste estimable tant qu'il est observable **au fil du temps**, même si aucune mesure isolée ne le détermine.

4 Conclusion

- **Kalman et EKF** : le Kalman est exact dans le cas linéaire gaussien et son incertitude se calcule à l'avance : l'EKF dépend de la linéarisation et son incertitude traduit la géométrie du problème
- **Réglage** : le gain, donc l'estimé, ne dépend que du rapport entre bruit de modèle et bruit de mesure : leur niveau absolu ne fixe que l'incertitude annoncée. Un filtre se juge sur sa précision et sur la cohérence de son incertitude
- **Absence de mesure** : le filtre prédit et son incertitude croît de façon réaliste : il se recale dès le retour des mesures
- **Observabilité** : elle se lit dans les jacobiennes. Une grandeur qu'aucune mesure ne voit directement n'est estimée que par le mouvement, donc moins bien