TP 3 - Bornes de Cramér-Rao

Optimisation de manoeuvre et comparaison avec le filtre de Kalman étendu

---

Colin Gibet & Tom Cuel

October 28, 2026

Contents

1 Question 0 – Information de Fisher pour un bruit gaussien additif **2**

2 Question 1 – Manoeuvre optimale pour le pistage par mesures d'angles **3**
2.1 Question 1a – Calcul de la BCR (dynamique non bruitée) 3
2.2 Question 1b – Cas $\varphi = 0$: sans manoeuvre, l'état n'est pas observable 3
2.3 Question 1c – Meilleur choix de φ 4

3 Question 2 – BCR avec bruit de dynamique et comparaison à l'EKF **6**
3.1 Question 2a – BCR bayésienne récursive 6
3.2 Question 2b – Comparaison BCR / EKF 7
3.3 Question 2c – Analyses complémentaires 10

4 Conclusion **11**

1 Question 0 – Information de Fisher pour un bruit gaussien additif

On observe $y = (y_1, \dots, y_n)$ avec $y_i = h_i(\theta) + \epsilon_i$, $\epsilon_i \sim \mathcal{N}(0, \sigma_i^2)$ indépendants, $\theta \in \mathbb{R}^d$ et $h_i : \mathbb{R}^d \to \mathbb{R}$. Montrons que

$$J(\theta) = \sum_{i=1}^{n} \frac{1}{\sigma_i^2} \left(\frac{\partial h_i}{\partial \theta}(\theta) \right)^T \left(\frac{\partial h_i}{\partial \theta}(\theta) \right)$$

Notations : $\frac{\partial h_i}{\partial \theta} = \left[\frac{\partial h_i}{\partial \theta_1} \ \cdots \ \frac{\partial h_i}{\partial \theta_d} \right]$ est une ligne $(1 \times d)$, et $\nabla_\theta h_i = \left(\frac{\partial h_i}{\partial \theta} \right)^T$ la colonne correspondante $(d \times 1)$. Le produit $\nabla_\theta h_i \, \nabla_\theta h_i^T = \left(\frac{\partial h_i}{\partial \theta} \right)^T \frac{\partial h_i}{\partial \theta}$ est donc une matrice $d \times d$.

1. Loi de chaque mesure : À θ fixé, $h_i(\theta)$ est une constante et $y_i = h_i(\theta) + \epsilon_i$ est une gaussienne décalée :

$$y_i \mid \theta \sim \mathcal{N}\big(h_i(\theta), \sigma_i^2\big), \qquad p(y_i \mid \theta) = \frac{1}{\sqrt{2\pi}\,\sigma_i} \exp\left(-\frac{(y_i - h_i(\theta))^2}{2\sigma_i^2} \right)$$

2. Log-vraisemblance : Les bruits étant indépendants, la vraisemblance est le produit des densités, et son logarithme une somme :

$$\ln p(y \mid \theta) = \ln \prod_{i=1}^{n} p(y_i \mid \theta) = \sum_{i=1}^{n} \left[-\ln\left(\sqrt{2\pi}\,\sigma_i\right) - \frac{(y_i - h_i(\theta))^2}{2\sigma_i^2} \right] = -\sum_{i=1}^{n} \frac{(y_i - h_i(\theta))^2}{2\sigma_i^2} + c$$

où $c = -\sum_i \ln(\sqrt{2\pi}\sigma_i)$ ne dépend pas de θ : elle disparaît à la dérivation.

3. Gradient (score) : On dérive chaque terme par rapport à θ_j avec la règle de dérivation en chaîne, $\frac{\partial}{\partial \theta_j}(y_i - h_i)^2 = -2(y_i - h_i)\frac{\partial h_i}{\partial \theta_j}$:

$$\frac{\partial}{\partial \theta_j} \ln p(y \mid \theta) = -\sum_{i=1}^{n} \frac{-2\,(y_i - h_i(\theta))}{2\sigma_i^2} \frac{\partial h_i}{\partial \theta_j} = \sum_{i=1}^{n} \frac{y_i - h_i(\theta)}{\sigma_i^2} \frac{\partial h_i}{\partial \theta_j}$$

En rangeant les d composantes dans une colonne, et puisque $y_i - h_i(\theta) = \epsilon_i$ sous le vrai paramètre :

$$\boxed{\nabla_\theta \ln p(y \mid \theta) = \sum_{i=1}^{n} \frac{y_i - h_i(\theta)}{\sigma_i^2} \nabla_\theta h_i(\theta) = \sum_{i=1}^{n} \frac{\epsilon_i}{\sigma_i^2} \nabla_\theta h_i(\theta)}$$

Vérification : $\mathbb{E}[\epsilon_i] = 0$ et $\nabla_\theta h_i(\theta)$ est déterministe, donc $\mathbb{E}\big[\nabla_\theta \ln p\big] = \sum_i \frac{\mathbb{E}[\epsilon_i]}{\sigma_i^2} \nabla_\theta h_i = 0$: le score est bien centré, comme dans le cas général du cours.

4. Information de Fisher (forme « produit de gradients ») : On développe le produit du score par lui-même. La somme sur i et la somme sur j donnent une double somme :

$$\nabla_\theta \ln p \, \nabla_\theta \ln p^T = \left(\sum_{i=1}^{n} \frac{\epsilon_i}{\sigma_i^2} \nabla_\theta h_i \right) \left(\sum_{j=1}^{n} \frac{\epsilon_j}{\sigma_j^2} \nabla_\theta h_j \right)^T = \sum_{i=1}^{n} \sum_{j=1}^{n} \frac{\epsilon_i \epsilon_j}{\sigma_i^2 \sigma_j^2} \nabla_\theta h_i \, \nabla_\theta h_j^T$$

Seuls les ϵ sont aléatoires : l'espérance passe sur eux. Les bruits sont indépendants et centrés, donc

$$\mathbb{E}[\epsilon_i \epsilon_j] = \begin{cases} \mathbb{E}[\epsilon_i]\,\mathbb{E}[\epsilon_j] = 0 & \text{si } i \neq j \text{ (termes croisés nuls)} \\ \mathbb{E}[\epsilon_i^2] = \sigma_i^2 & \text{si } i = j \end{cases} \qquad \text{soit} \quad \mathbb{E}[\epsilon_i \epsilon_j] = \delta_{ij}\, \sigma_i^2$$

Il ne reste que la diagonale de la double somme :

$$J(\theta) = \mathbb{E}\Big[\nabla_\theta \ln p \, \nabla_\theta \ln p^T\Big] = \sum_{i,j} \frac{\delta_{ij}\sigma_i^2}{\sigma_i^2 \sigma_j^2} \nabla_\theta h_i \nabla_\theta h_j^T = \sum_{i=1}^{n} \frac{\sigma_i^2}{\sigma_i^4} \nabla_\theta h_i \nabla_\theta h_i^T = \boxed{\sum_{i=1}^{n} \frac{1}{\sigma_i^2} \left(\frac{\partial h_i}{\partial \theta} \right)^T \frac{\partial h_i}{\partial \theta}}$$

5. Vérification par la forme hessienne : $J = -\mathbb{E}\big[\frac{\partial^2}{\partial \theta^2} \ln p\big]$. On redérive le score par rapport à θ_k, avec la règle du produit :

$$\frac{\partial^2 \ln p}{\partial \theta_k \, \partial \theta_j} = \sum_{i=1}^{n} \frac{1}{\sigma_i^2} \left[\underbrace{-\frac{\partial h_i}{\partial \theta_k} \frac{\partial h_i}{\partial \theta_j}}_{\text{dérivée de } (y_i - h_i)} + \big(y_i - h_i(\theta)\big) \frac{\partial^2 h_i}{\partial \theta_k \, \partial \theta_j} \right]$$

Sous forme matricielle, avec $y_i - h_i(\theta) = \epsilon_i$:

$$\frac{\partial^2}{\partial \theta^2} \ln p(y \mid \theta) = -\sum_{i=1}^{n} \frac{1}{\sigma_i^2} \nabla_\theta h_i \nabla_\theta h_i^T + \sum_{i=1}^{n} \frac{\epsilon_i}{\sigma_i^2} \frac{\partial^2 h_i}{\partial \theta^2}$$

Le second terme, qui contient la courbure de h_i, est multiplié par ϵ_i : il est d'espérance nulle. Il reste $-\mathbb{E}\big[\frac{\partial^2}{\partial \theta^2} \ln p\big] = \sum_i \frac{1}{\sigma_i^2} \nabla_\theta h_i \nabla_\theta h_i^T$, **le même résultat**. Conséquence : l'information ne dépend que des **dérivées premières** de h, et non de sa courbure.

6. Forme matricielle : On empile les mesures : $h = (h_1, \dots, h_n)^T$, de jacobienne $H = \frac{\partial h}{\partial \theta}$ ($n \times d$, sa ligne i est $\frac{\partial h_i}{\partial \theta}$), et $R = \mathrm{diag}(\sigma_1^2, \dots, \sigma_n^2)$. Comme $R^{-1} = \mathrm{diag}(1/\sigma_i^2)$ est diagonale,

$$H^T R^{-1} H = \sum_{i=1}^{n} \big(\text{ligne } i \text{ de } H\big)^T \frac{1}{\sigma_i^2} \big(\text{ligne } i \text{ de } H\big) = \sum_{i=1}^{n} \frac{1}{\sigma_i^2} \left(\frac{\partial h_i}{\partial \theta} \right)^T \frac{\partial h_i}{\partial \theta} \qquad \Rightarrow \qquad \boxed{J(\theta) = H^T R^{-1} H}$$

La formule reste vraie pour des bruits gaussiens corrélés de covariance R quelconque, avec $\ln p = -\frac{1}{2}(y - h(\theta))^T R^{-1} (y - h(\theta)) + c$.

C'est exactement le terme de correction des récursions utilisées dans la suite : $H_k^T R_k^{-1} H_k$, ajouté à l'information transportée par la dynamique.

2 Question 1 – Manoeuvre optimale pour le pistage par mesures d'angles

Un observateur mobile ne mesure que la **direction** d'un émetteur (pistage passif). L'émetteur va en ligne droite à vitesse constante, sans bruit de dynamique :

$$X_k = (x_k, y_k, \dot{x}_k, \dot{y}_k)^T, \qquad X_k = \Phi X_{k-1}, \quad \Phi = \begin{bmatrix} 1 & 0 & T & 0 \\ 0 & 1 & 0 & T \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}, \qquad \theta_k = \operatorname{atan2}(y_k - y_k^o,\, x_k - x_k^o) + \epsilon_k, \quad \epsilon_k \sim \mathcal{N}(0, \sigma^2)$$

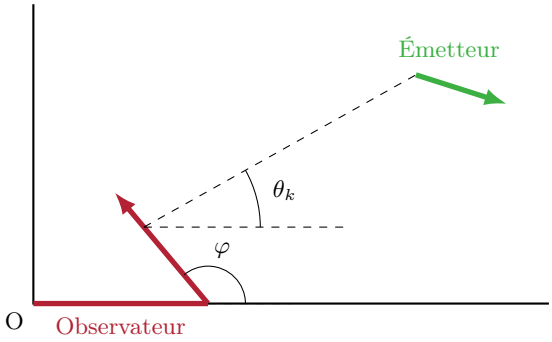


Figure 1: Pistage par mesures d'angles : l'observateur avance selon $+x$, puis prend le cap φ, il mesure l'azimut θ_k de l'émetteur

2.1 Question 1a – Calcul de la BCR (dynamique non bruitée)

La dynamique est déterministe et inversible : l'information se **transporte** par Φ, puis chaque mesure en **ajoute** (question 0, avec une mesure scalaire) :

$$\boxed{J_k = \Phi^{-T} J_{k-1} \Phi^{-1} + \frac{1}{\sigma^2} \nabla_{X_k} h_k \, \nabla_{X_k} h_k^T, \qquad J_0 = P_0^{-1}, \qquad \mathrm{BCR}_k = J_k^{-1}}$$

Jacobienne de la mesure : avec $\mathrm{d}\operatorname{atan2}(\Delta y, \Delta x) = \frac{-\Delta y\,\mathrm{d}\Delta x + \Delta x\,\mathrm{d}\Delta y}{\Delta x^2 + \Delta y^2}$, $\Delta x = x_k - x_k^o$, $\Delta y = y_k - y_k^o$, $r_k^2 = \Delta x^2 + \Delta y^2$

$$\frac{\partial h_k}{\partial X_k} = \frac{1}{r_k^2} \begin{bmatrix} -\Delta y & \Delta x & 0 & 0 \end{bmatrix}$$

Le gradient est **perpendiculaire à la ligne de visée** et de norme $1/r_k$: une mesure d'angle ne renseigne que sur le déplacement transverse de la cible, jamais sur sa distance. Les vitesses n'apparaissent pas : elles ne sont apprises qu'à travers la succession des positions.

```
# cramer_rao_deterministe.py
def predict(self, F):
    F_inv = np.linalg.inv(F)
    self.J = F_inv.T @ self.J @ F_inv            # J <- F^-T J F^-1
def update(self, H, R):
    self.J = self.J + H.T @ np.linalg.solve(R, H) # J <- J + H^T R^-1 H

# q1_manoeuvre.py
def bearing_jacobian(x, observer_xy):
    dx, dy = x[0] - observer_xy[0], x[1] - observer_xy[1]
    r2 = dx**2 + dy**2
    Jdx = -dy / r2                    # d theta / dx
    Jdy = dx / r2                     # d theta / dy
    Jdvx = 0.0                        # l'angle ne depend pas des vitesses
    Jdvy = 0.0
```

Les jacobiennes ont été vérifiées par différences finies. La borne est **locale :** elle évalue H_k sur la trajectoire nominale de l'émetteur.

2.2 Question 1b – Cas $\varphi = 0$: sans manoeuvre, l'état n'est pas observable

Si l'observateur va tout droit à vitesse constante, toute trajectoire de la forme $p_\alpha(k) = o(k) + \alpha\,(p(k) - o(k))$, avec $o(k)$ la position de l'observateur et $p(k)$ celle de la cible, est elle aussi rectiligne uniforme et donne **exactement les mêmes angles** (écart numérique de 10^{-16} rad) : une cible deux fois plus loin et deux fois plus rapide (par rapport à l'observateur) est indiscernable.

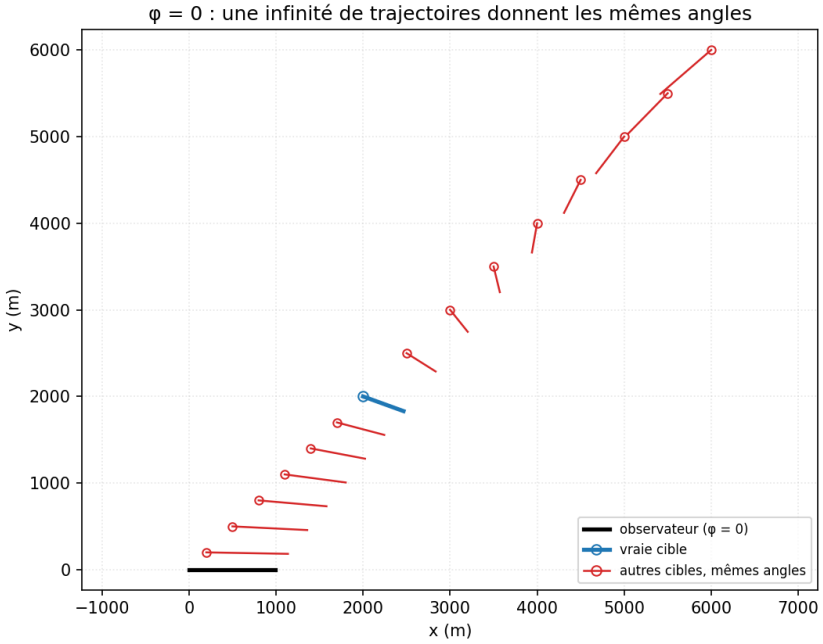


Figure 2: $\varphi = 0$: la vraie cible (bleu) et d'autres trajectoires rectilignes uniformes qui donnent les mêmes angles (rouge)

Que dit la BCR sans information a priori ? On remplace P_0 par une covariance immense (10^{14}) et on calcule J_{100} :

- $\varphi = 0$ **:** la plus petite valeur propre de J vaut $2 \cdot 10^{-14}$, c'est-à-dire zéro à la précision près. J est **singulière** et la BCR est **infinie** dans la direction correspondante (le facteur d'échelle α) : la borne de position vaut $8 \cdot 10^6$ m, uniquement limitée par l'a priori artificiel
- $\varphi = 115°$ **:** toutes les valeurs propres sont strictement positives et la borne de position vaut 119 m

Avec l'a priori du TP, la borne à $\varphi = 0$ reste finie (environ 960 m), mais elle est entièrement due à l'a priori : les mesures n'ont rien appris sur la distance.

2.3 Question 1c – Meilleur choix de φ

La BCR ne dépend que du modèle : on la calcule pour chaque cap φ (pas de 0.1°, commande `python q1_manoeuvre.py -step-deg 0.1 -output-dir figures`, aussi lancée par `tp3_analyses.py`) et on garde celui qui minimise l'erreur de position finale $\sqrt{\sigma_{x_n}^2 + \sigma_{y_n}^2}$.

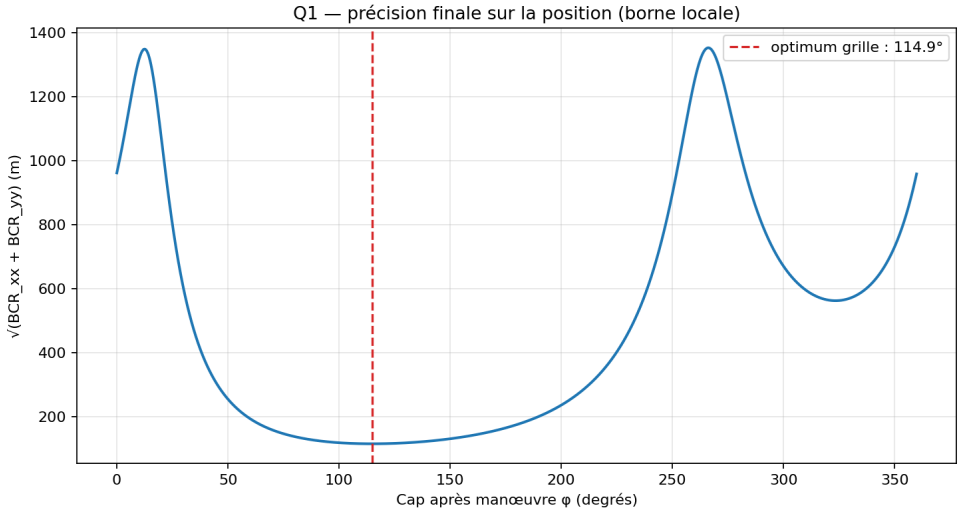


Figure 3: Borne sur l'erreur de position finale selon le cap après manoeuvre

$\varphi^* = 114.9°$, pour une erreur de position finale minimale de **115.5 m** (borne), contre 960 m sans manoeuvre et plus de 1300 m dans les pires cas ($\varphi \approx 12°$ et 266°). On retrouve l'optimum d'environ 115° annoncé dans le cours.

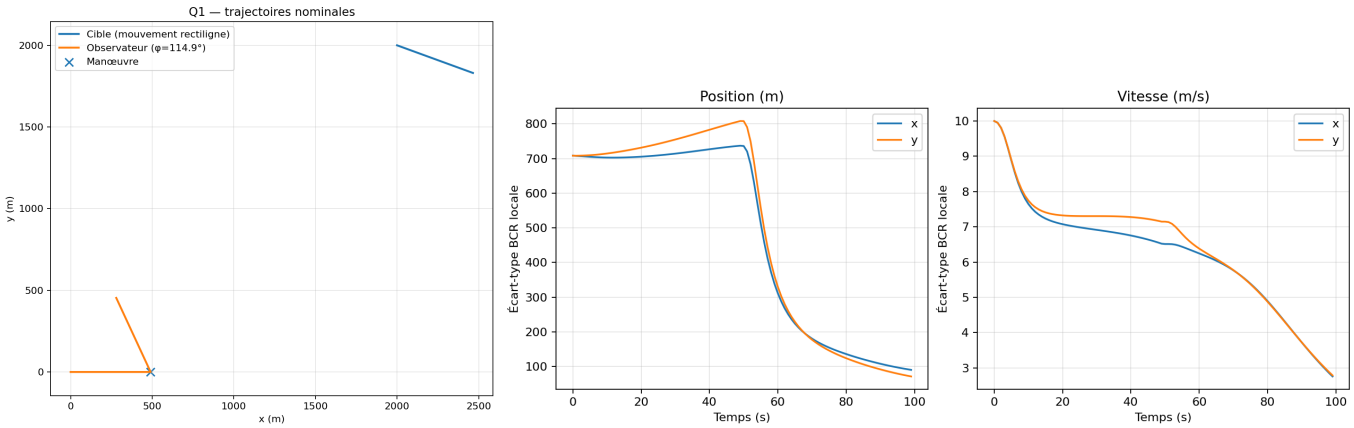


Figure 4: Manoeuvre optimale : trajectoires (gauche) et écarts-types de la borne au cours du temps (droite)

Qu'observe-t-on ?

- **Avant la manoeuvre** ($k < 50$), l'incertitude de position **ne diminue pas**, elle augmente même un peu : la direction de la cible est bien connue, mais pas sa distance, et l'incertitude de vitesse se reporte sur la position au fil du temps
- **Juste après la manoeuvre**, l'erreur de position chute brutalement de 800 m à environ 200 m en une vingtaine de mesures, puis continue de décroître jusqu'à environ 100 m : le changement de cap rend la distance observable

Pourquoi 115° **?** Ce qui rend la distance observable, c'est que l'observateur **ne suit plus** un mouvement rectiligne uniforme. La manoeuvre change sa vitesse de $\Delta v = v_{\text{après}} - v_{\text{avant}}$. Seule la composante de Δv **perpendiculaire à la ligne de visée** fait tourner celle-ci d'une façon qui dépend de la distance : c'est l'effet de parallaxe qui permet de trianguler.

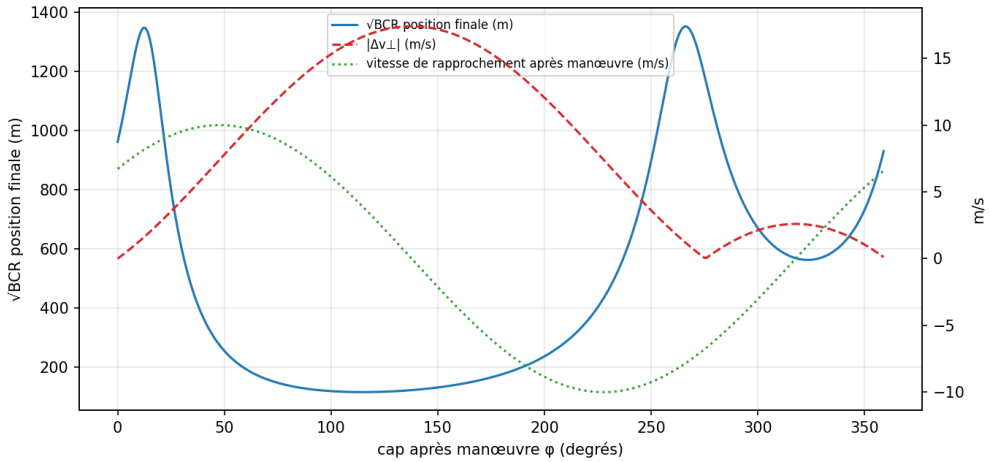


Figure 5: Borne de position finale (bleu), composante perpendiculaire à la ligne de visée de la variation de vitesse (rouge) et vitesse de rapprochement après manoeuvre (vert)

- Au moment de la manoeuvre, la ligne de visée fait $\beta = 47.8°$ avec l'axe x, et la cible est à 2.6 km
- $|\Delta v_\perp|$ est **nul** pour $\varphi = 0$ (pas de manoeuvre) et pour $\varphi = 276°$ (Δv alignée avec la ligne de visée) : on retrouve les deux pics de la borne (12° et 266°)
- $|\Delta v_\perp|$ est **maximal** vers 138°, l'optimum réel est un peu en deçà (115°), car il garde une vitesse de rapprochement positive

Pour aller plus loin : instant de la manoeuvre : On refait la recherche du cap optimal en déplaçant le changement de cap de $k = 5$ à $k = 95$ (figure 6).

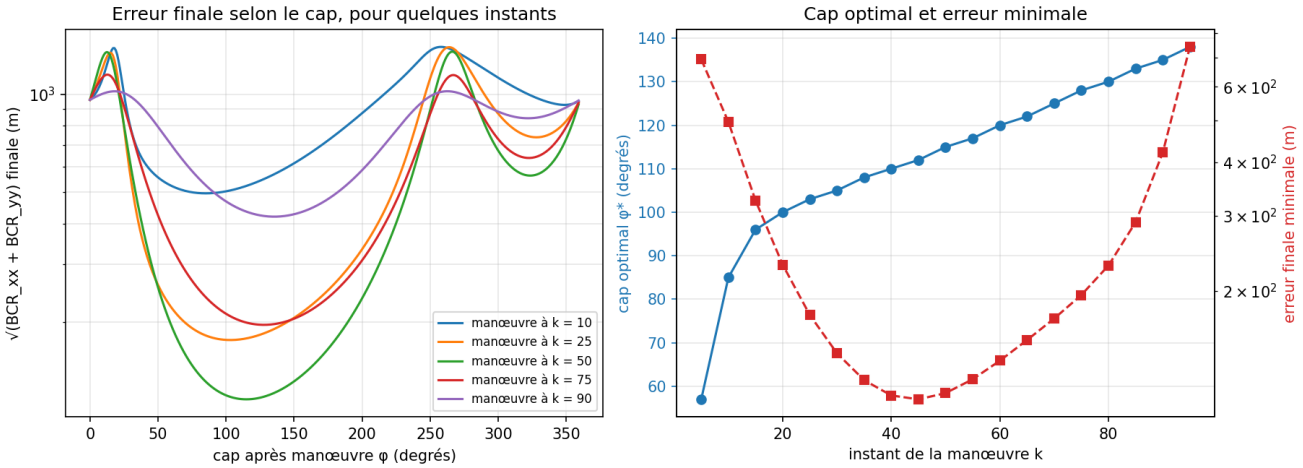


Figure 6: Gauche : borne de position finale selon le cap, pour quelques instants de manoeuvre. Droite : cap optimal (bleu) et erreur minimale (rouge) selon l'instant de la manoeuvre

- **Le meilleur instant est vers le milieu :** l'erreur minimale vaut 112 m pour une manoeuvre à $k = 45$ et 116 m à $k = 50$, mais 496 m à $k = 10$ et 421 m à $k = 90$. Trop tôt, la direction de la cible est encore mal connue et trop tard, il reste trop peu de mesures après la manoeuvre pour exploiter la parallaxe
- **Le cap optimal augmente régulièrement avec l'instant** (de 85° à $k = 10$ à 135° à $k = 90$) : il suit la rotation de la ligne de visée vers la cible au cours du temps
- **Les deux pics restent** (vers 15° et 265°) quel que soit l'instant : ce sont les caps qui ne créent pas de vitesse perpendiculaire à la ligne de visée
- Quand on manoeuvre trop tard ($k = 90$), la courbe s'aplatit : le cap compte moins, car il reste peu de mesures pour en tirer parti

3 Question 2 – BCR avec bruit de dynamique et comparaison à l'EKF

On reprend la cible du TP1 : elle roule sur l'axe x ($X_k = (s_k, v_k)$, $\Delta t = 1$ s), avec un bruit de dynamique $Q = \mathrm{diag}(10^{-4}, 10^{-2})$, et un capteur placé en $C = (0, -20)$ mesure l'angle $\theta_k = \mathrm{atan2}(20, s_k) + v_k$, $v_k \sim \mathcal{N}(0, 1^{\circ 2})$. A priori : $X_0 \sim \mathcal{N}\big((0, 5), \mathrm{diag}(100, 1)\big)$, soit $\sigma_s = 10$ m et $\sigma_v = 1$ m/s. Durée : 30 pas.

3.1 Question 2a – BCR bayésienne récursive

Avec un bruit de dynamique, l'état n'est plus une fonction déterministe de X_0 : on utilise la borne a posteriori (PCRB), sous forme récursive :

$$J_{k+1} = \underbrace{\left(\Phi J_k^{-1} \Phi^T + Q\right)^{-1}}_{\text{prédiction (perte)}} + \underbrace{\mathbb{E}_{X_{k+1}}\left[H_{k+1}^T R^{-1} H_{k+1}\right]}_{\text{mesure (gain, Monte-Carlo)}}, \qquad H(s) = \begin{bmatrix} \dfrac{-20}{s^2 + 400} & 0 \end{bmatrix}$$

L'espérance porte sur la **loi marginale** de l'état (pas sur la loi a posteriori du filtre) : on tire 15 000 états initiaux selon l'a priori et on les propage avec la dynamique **supposée par la borne** (avec ou sans Q).

```
# cramer_rao_general.py
# COMPLETER START
H = np.asarray(H_jacobian(x), dtype=float).reshape(m, n)
information += H.T @ np.linalg.solve(R, H)      # H(x)^T R^-1 H(x), moyenne sur les etats
# COMPLETER END

# COMPLETER START
P_pred = _sym(F @ np.linalg.inv(self.J) @ F.T + Q)   # P = F J^-1 F^T + Q
# COMPLETER END

# COMPLETER START
self.J = _sym(self.J + J_measurement)               # J <- J_pred + E[H^T R^-1 H]
# COMPLETER END

# COMPLETER START
dx, dy = s - xs, 0.0 - ys
Jdx = -dy / (dx**2 + dy**2)       # d atan2(dy, dx) / ds = -dy / r^2
Jdvx = 0.0                        # l'angle ne depend pas de la vitesse
# COMPLETER END
```

La prédiction est écrite sous forme de covariance ($FJ^{-1}F^T + Q$) : elle accepte $Q = 0$ et une matrice F singulière. C'est la forme informationnelle du filtre de Kalman : si h était linéaire, la borne serait exactement la covariance du filtre de Kalman.

3.2 Question 2b – Comparaison BCR / EKF

Trois expériences, 500 simulations chacune (`python tp3_analyses.py Q2`, ou `python experiments.py -runs 500 -mc 15000 -output-dir figures`) :

- **Q2b-(1), expérience A :** bruit de dynamique Q nul pour le monde, l'EKF et la borne
- **Q2b-(2), expérience B :** Q non nul pour le monde et l'EKF, mais borne calculée avec $Q = 0$
- **Q2b-(3), expérience C :** Q non nul pour le monde, l'EKF et la borne

B et C utilisent exactement les mêmes trajectoires, mesures et résultats de l'EKF : seule la borne change. Chaque figure montre la borne $3\sqrt{(J_k^{-1})_{ss}}$, l'incertitude moyenne annoncée par l'EKF $3\sqrt{\mathbb{E}[(P_k^{EKF})_{ss}]}$ et l'erreur réelle de l'EKF 3 RMSE.

		position s (m)			vitesse v (m/s)		
Expérience	Q (monde / EKF / borne)	$3\sqrt{\text{BCR}}$	3 RMSE	$3\sqrt{P}$	$3\sqrt{\text{BCR}}$	3 RMSE	$3\sqrt{P}$
A – Q2b-(1)	0 / 0 / 0	5.0	16.8	7.7	0.19	0.74	0.28
B – Q2b-(2)	Q / Q / 0	5.0	13.7	13.4	0.19	1.17	1.20
C – Q2b-(3)	Q / Q / Q	10.6	13.7	13.4	1.12	1.17	1.20

Table 1: Valeurs à l'instant final ($k = 30$)

Q2b-(1) : Q nul pour l'EKF et la borne (expérience A)

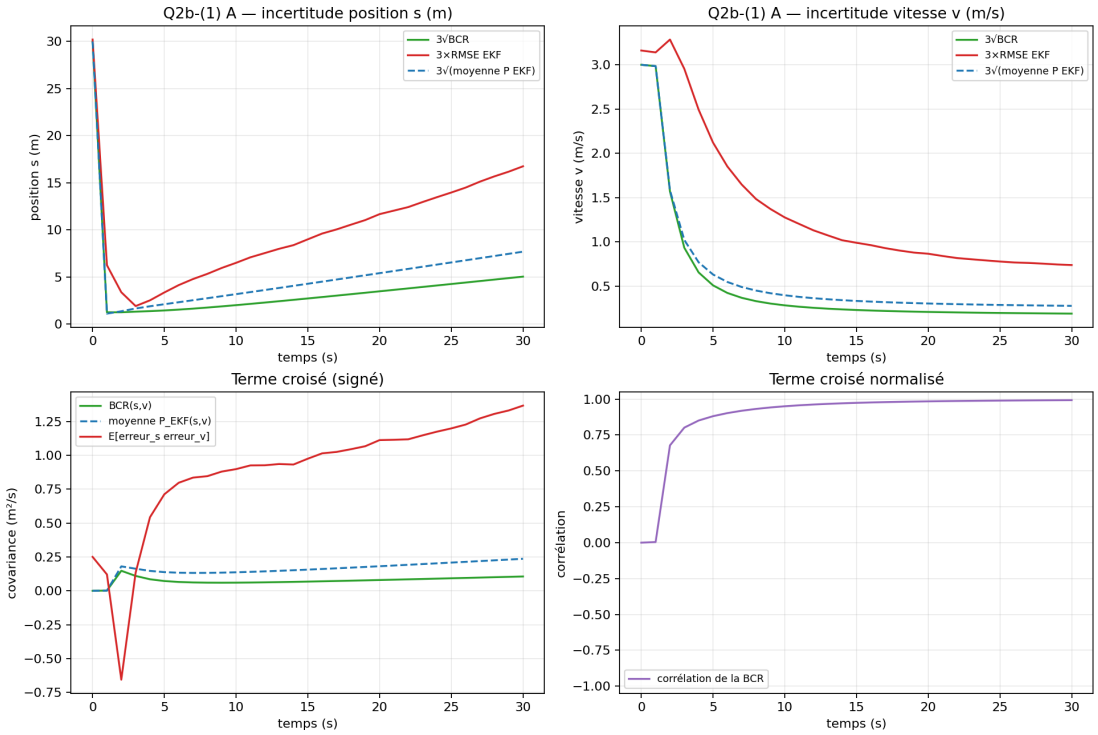


Figure 7: Expérience A : modèle idéal sans bruit de dynamique

Qu'observe-t-on, et pourquoi ?

- **La borne chute dès la première mesure** (de 30 m à environ 1 m en 3σ). Au départ, la cible est à 20 m du capteur : un degré d'angle y correspond à 35 cm. Une seule mesure d'angle fixe donc la position bien mieux que l'a priori ($\sigma_s = 10$ m)
- **Puis elle remonte**, alors que les mesures s'accumulent. La cible s'éloigne, et l'angle varie de moins en moins avec la position : la sensibilité de la mesure vaut $\left|\frac{\partial\theta}{\partial s}\right| = \frac{20}{s^2+400}$, environ 57 fois plus faible à $s = 150$ m qu'à $s = 0$. Les nouvelles mesures n'apportent presque plus d'information et corrigent peu l'estimation
- **L'incertitude de vitesse se reporte sur la position :** Une petite erreur de vitesse s'accumule avec le temps ($\delta s_k \approx \delta s_0 + k\,\Delta t\,\delta v$) et devient une erreur de position croissante. C'est pourquoi la position et la vitesse deviennent presque parfaitement corrélées (corrélation de la borne proche de 1) : une erreur de vitesse produit une erreur de position de même signe

- **L'EKF est loin de la borne :** son erreur réelle vaut 3 fois la borne en position et 4 fois en vitesse. La borne est la performance du meilleur estimateur possible, l'EKF, lui, linéarise la mesure autour de son estimation courante. Au départ, l'incertitude (10 m) est du même ordre que la distance au capteur (20 m), où l'angle est très non linéaire : si l'estimation est mauvaise, la linéarisation l'est aussi, et la correction envoie le filtre au mauvais endroit. Comme $Q = 0$, il ne peut jamais oublier cette erreur de départ

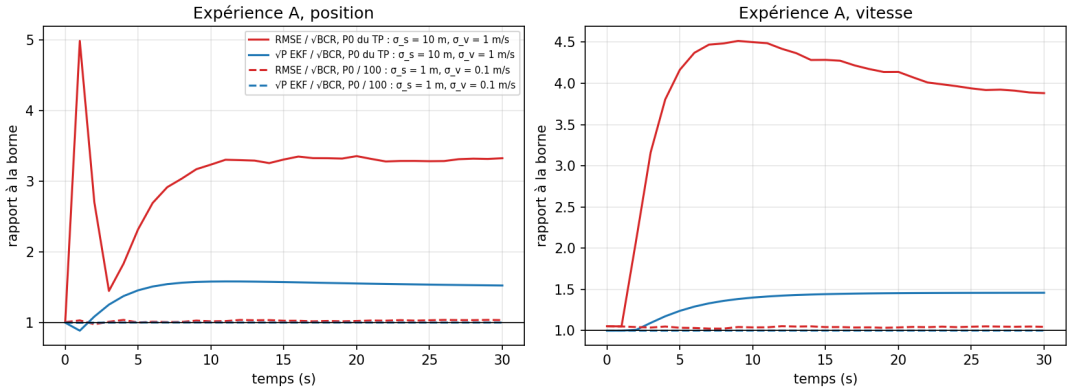


Figure 8: Expérience A : rapport entre l'erreur de l'EKF (rouge), son incertitude annoncée (bleu) et la borne, pour l'a priori du TP (trait plein) et un a priori 10 fois plus serré (tirets)

  Avec $\sigma_s = 1$ m, la linéarisation est valable dès le départ : l'EKF atteint la borne à 4 % près, et son incertitude annoncée coïncide avec elle. **L'EKF est alors efficace** ; l'écart de l'expérience A ne vient pas de la borne, mais de la non-linéarité à l'échelle de l'incertitude initiale.
- **L'EKF se croit meilleur qu'il n'est :** $\sqrt{P}$ est l'incertitude qu'il annonce, la RMSE l'erreur qu'il commet réellement : ici la RMSE est deux fois plus grande. Environ 9 % des simulations sortent de l'intervalle $\pm 3\sigma$ annoncé, alors qu'un filtre bien calibré n'en laisserait sortir que 0.3 %

Quand la cible s'éloigne, les mesures d'angle deviennent peu informatives : la borne remonte, et l'incertitude de vitesse se transforme en incertitude de position. L'écart entre l'EKF et la borne ne vient pas de là : il vient de la forte non-linéarité au départ, qui fait échouer la linéarisation dans certaines simulations, sans que le filtre s'en rende compte.

Q2b-(2) : Q non nul pour l'EKF, nul pour la borne (expérience B)

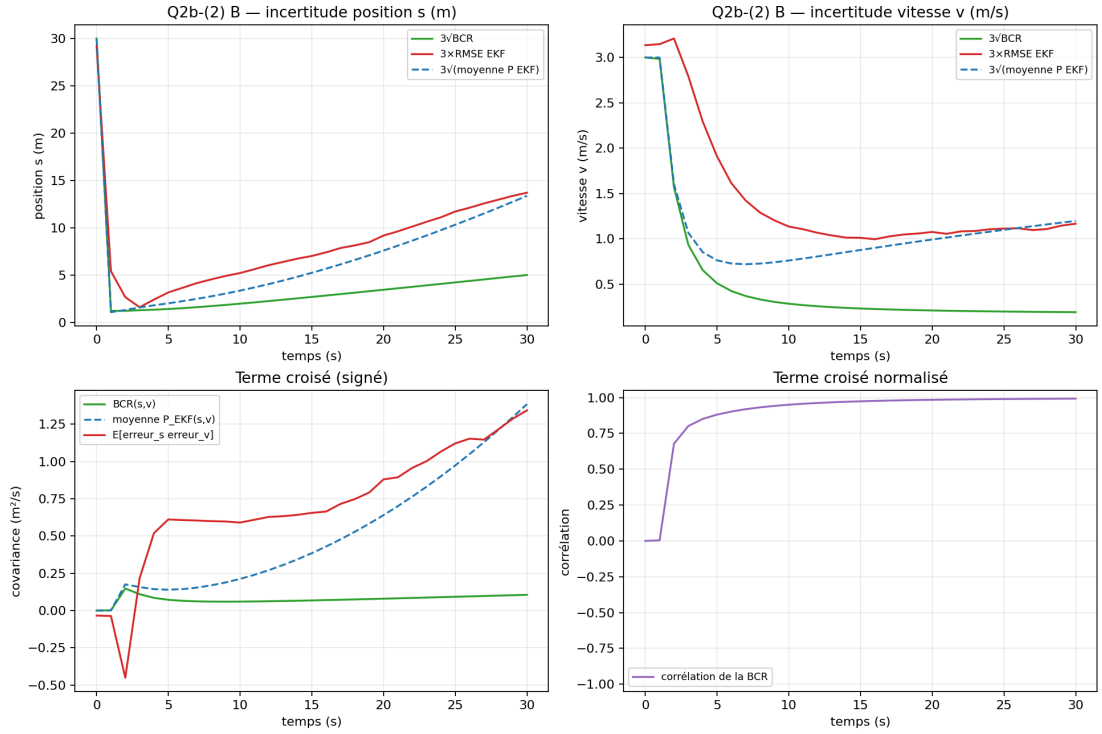


Figure 9: Expérience B : EKF réglé avec le vrai Q, borne calculée avec $Q = 0$

Borne mal spécifiée : Calculée avec $Q = 0$, la borne suppose que la vitesse est constante : chaque mesure aide à

l'estimer **pour toujours**, et la borne de vitesse tend vers 0. Mais la vraie vitesse change à chaque pas : la vitesse « apprise » se périme. Cette borne est donc **trop optimiste :** elle ne borne pas l'erreur du vrai problème (EKF à 1.17 m/s contre une « borne » de 0.19 m/s en vitesse), et l'écart, qui grandit avec le temps, ne dit rien de la qualité du filtre. La borne de position, elle, ressemble à celle de l'expérience A : sans bruit de dynamique, le modèle de la borne est le même.

Q2b-(3) : même Q non nul pour l'EKF et la borne (expérience C)

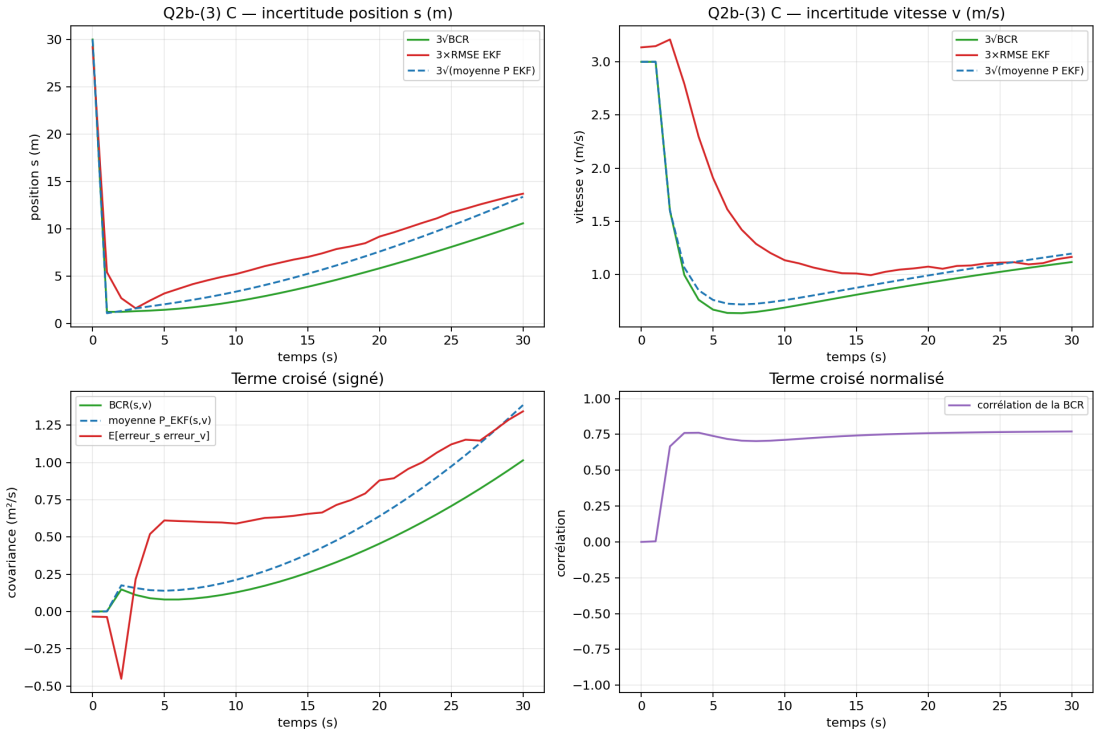


Figure 10: Expérience C : borne et EKF cohérents avec le vrai modèle

- **Borne cohérente :** Avec le vrai Q, la borne de vitesse ($3\sqrt{\mathrm{BCR}}$) ne descend pas sous 0.65 m/s, puis remonte : la vitesse varie, l'information ancienne se périme (terme de perte Q dans la prédiction)
- **L'EKF s'en approche :** à la fin, son erreur de vitesse n'est que 5 % au-dessus de la borne, et celle de position 30 % au-dessus
- **Consistance :** l'incertitude annoncée par l'EKF est proche de son erreur réelle (13.4 m contre 13.7 m), et plus de 99 % des simulations restent dans $\pm 3\sigma$. Le bruit de dynamique « réinitialise » en partie le filtre et efface l'effet de la première linéarisation qui pénalisait l'expérience A

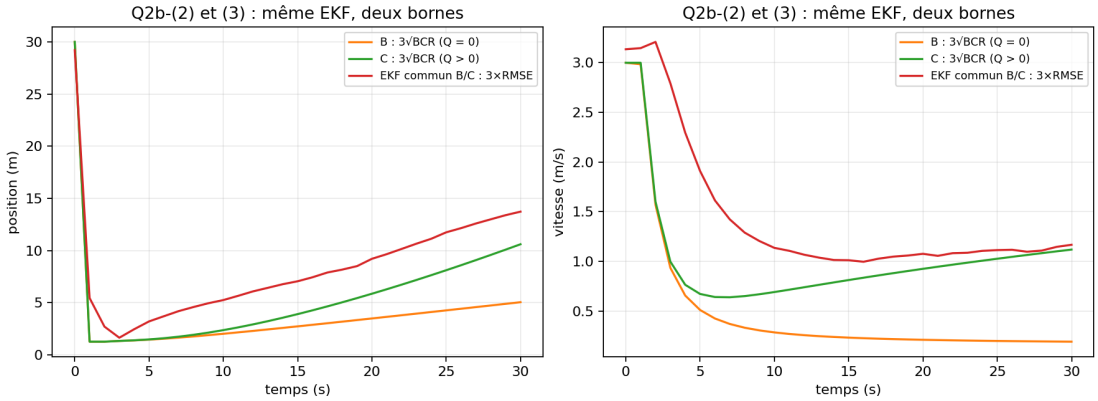


Figure 11: Q2b-(2) et (3) : même EKF, comparé à la borne calculée avec $Q = 0$ (B, orange) ou avec le vrai Q (C, vert)

Une borne ne vaut que pour le **modèle** avec lequel elle est calculée. Calculée avec un modèle plus favorable que la réalité (ici sans bruit de dynamique), elle est trop optimiste et n'a plus de sens. Avec le bon modèle, elle sert de référence : l'écart entre l'erreur d'un filtre et la borne mesure ce que le filtre perd (ici, la linéarisation de l'EKF au départ).

3.3 Question 2c – Analyses complémentaires

Efficacité et consistance au cours du temps : On trace deux rapports, qui valent 1 dans le cas idéal : RMSE/$\sqrt{\text{BCR}}$ (l'EKF atteint-il la borne ?) et $\sqrt{P_{EKF}}$/RMSE (l'EKF annonce-t-il la bonne incertitude ?).

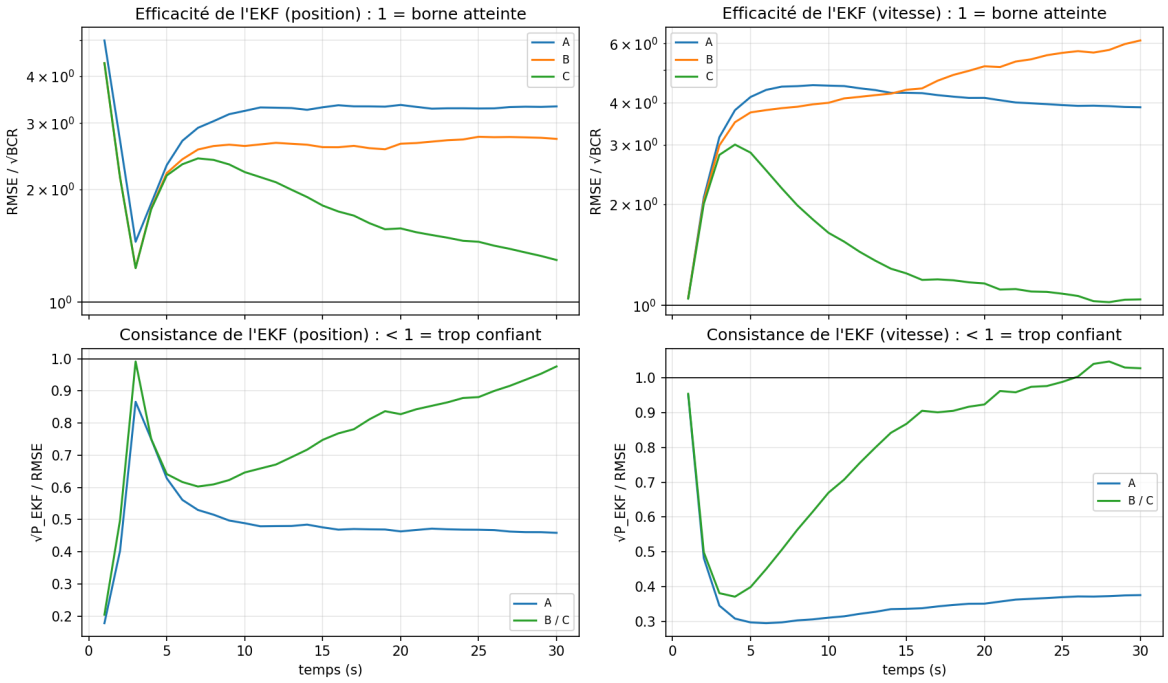


Figure 12: Haut : erreur de l'EKF rapportée à la borne. Bas : incertitude annoncée rapportée à l'erreur réelle (< 1 : filtre trop confiant)

- **C :** l'EKF **rejoint progressivement la borne** (vitesse à 1.04 à la fin, position encore en décroissance à 1.3), et sa consistance remonte vers 1 : le bruit de dynamique efface peu à peu l'erreur de départ
- **A :** le rapport reste bloqué vers 3.3 en position et 3.9 en vitesse, et l'EKF reste **trop confiant** ($\sqrt{P}$ à 0.4–0.5 fois l'erreur réelle en position, 0.3–0.4 en vitesse) : sans bruit de dynamique, rien n'efface l'erreur de départ
- **B :** le rapport à la borne grandit sans cesse en vitesse, ce qui montre seulement que cette borne ne correspond pas au vrai modèle

Erreurs normalisées et NEES : Si l'EKF est consistant, l'erreur divisée par l'écart-type annoncé suit une loi $\mathcal{N}(0,1)$, et le NEES moyen $\mathbb{E}\left[e_k^T P_k^{-1} e_k\right]$ vaut la dimension de l'état, ici 2.

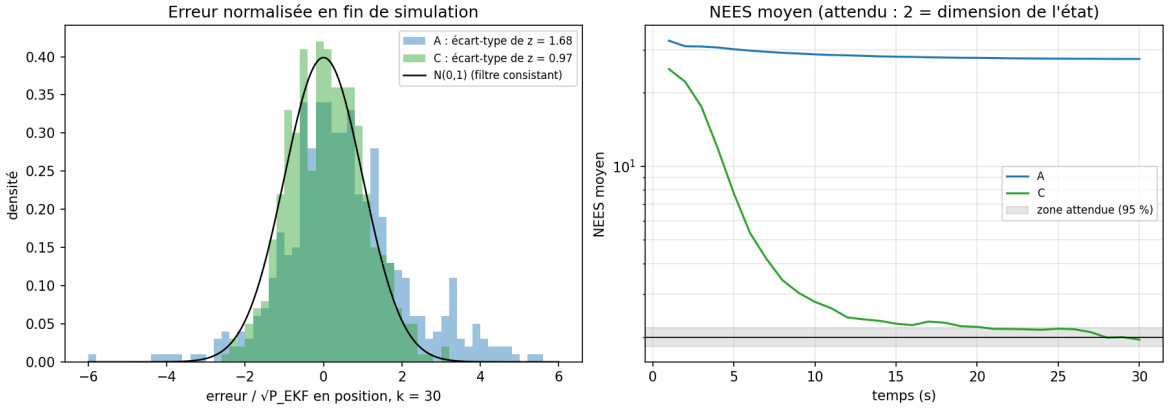


Figure 13: Gauche : erreur de position normalisée à $k = 30$, comparée à $\mathcal{N}(0,1)$. Droite : NEES moyen sur les 500 simulations (zone grise : intervalle attendu à 95 %)

Dans l'expérience C, l'erreur normalisée a un écart-type de 0.97 et le NEES moyen rejoint 2 à la fin (1.95) : l'EKF est consistant. Dans l'expérience A, l'écart-type vaut 1.68, avec une queue de grosses erreurs (jusqu'à 6 écarts-types), et le NEES moyen reste vers 28 : ce sont les simulations mal parties à la première correction, que l'EKF ne voit pas.

Réglage de Q dans l'EKF : On garde le monde et la borne de l'expérience C (vrai Q), mais l'EKF utilise $Q_{EKF} = \alpha\, Q$.

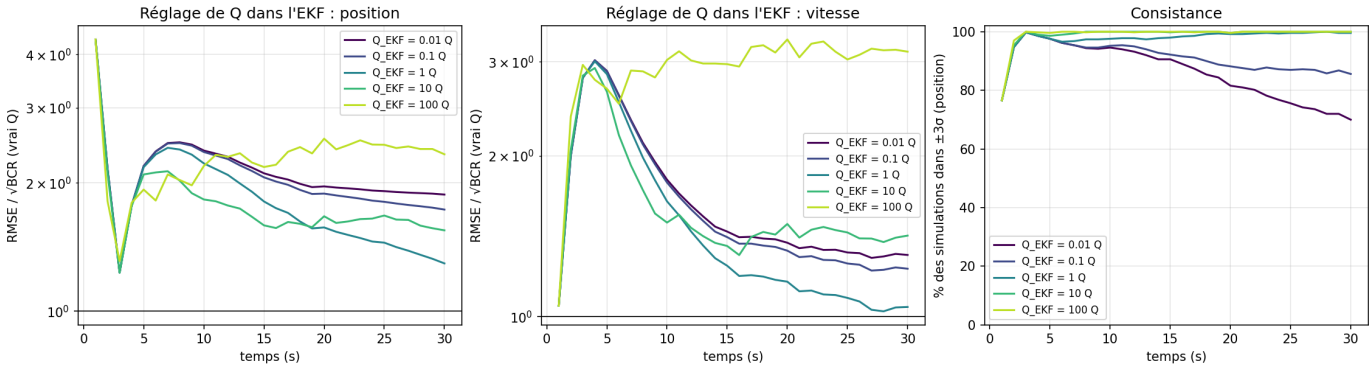


Figure 14: Erreur de l'EKF rapportée à la borne du vrai modèle (position, vitesse) et part des simulations dans $\pm 3\sigma$, selon le Q de l'EKF

Q_{EKF}/Q	0.01	0.1	1	10	100
RMSE / $\sqrt{\text{BCR}}$ position	1.88	1.73	**1.30**	1.55	2.33
RMSE / $\sqrt{\text{BCR}}$ vitesse	1.31	1.23	**1.04**	1.42	3.13
simulations dans $\pm 3\sigma$	70 %	86 %	**99.6 %**	100 %	100 %

Le vrai Q donne à la fois la meilleure précision et une bonne consistance : c'est le seul réglage qui approche la borne. Sous-estimer Q rend le filtre **trop confiant** (30 % des simulations hors de $\pm 3\sigma$ pour $Q/100$) : il croit la vitesse constante et réagit trop lentement à ses variations. Surestimer Q le garde consistant, mais **gaspille l'information :** il oublie trop vite les mesures passées et s'éloigne de la borne (facteur 3 en vitesse pour $100\,Q$). On retrouve la règle du TP1, mesurée cette fois par rapport à la meilleure performance possible.

Précision du Monte-Carlo de la borne : L'espérance $\mathbb{E}[H^T R^{-1} H]$ est estimée par Monte-Carlo : on mesure la dispersion de la borne finale sur 10 tirages.

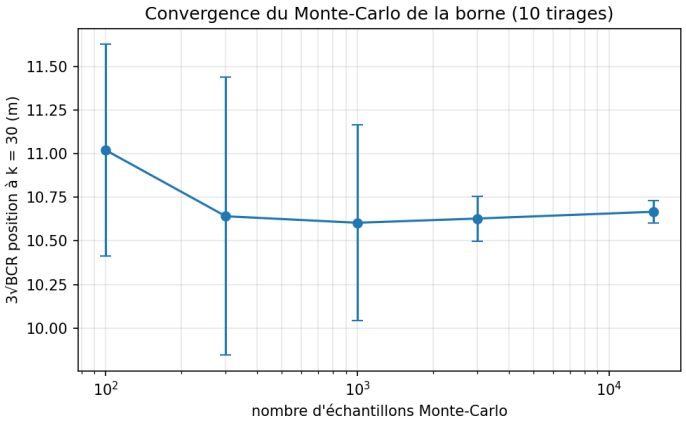


Figure 15: Borne de position finale (expérience C) selon le nombre d'échantillons Monte-Carlo : moyenne et écart-type sur 10 tirages

Avec 15 000 échantillons, la borne est connue à 0.6 % près (1.2 % avec 3000) et en dessous de 1000, la dispersion atteint 5 à 8 %. Les écarts mesurés entre l'EKF et la borne (4 à 30 % dans l'expérience C) sont donc bien réels, et non un artefact du Monte-Carlo.

4 Conclusion

- **Information de Fisher :** pour des mesures à bruit gaussien additif, $J = H^T R^{-1} H$. Chaque mesure informe dans la direction de son gradient, et une borne finie demande que ces directions couvrent tout l'état
- **Manoeuvre :** un observateur qui ne mesure que des angles ne peut pas estimer la distance s'il reste en mouvement rectiligne uniforme (borne infinie). La borne, calculable sans aucune mesure, permet de choisir la manoeuvre : ici un cap de 115° à mi-parcours, qui divise l'erreur finale de position par 8
- **BCR et EKF :** avec le bon modèle, l'EKF approche la borne et reste consistant. Il s'en écarte quand la non-linéarité est forte à l'échelle de l'incertitude (a priori large près du capteur), et l'atteint quand l'a priori est assez précis
- **Limite :** la borne doit être calculée avec le vrai modèle et sans bruit de dynamique, elle devient trop optimiste et ne borne plus rien